

요구사항 정의서

LangGraph 기반 반도체 FDC 이상감지 에이전트

2026.08.12 · PhotoEtch

항목	내용
작성일	2026.08.04
최종 수정일	2026.08.12
팀명	PhotoEtch
팀원	강연권 · 방대혁 · 신동원 · 천승현

2. 개요

2.1 목적

본 문서는 「LangGraph 기반 반도체 FDC 이상감지 에이전트 및 데이터 플랫폼」이 구현해야 할 기능·비기능 요구사항을 정의한다. 각 요구사항에 식별자(ID)와 수용 기준을 부여하여 이후 산출물인 시스템 설계서(8/14) 및 테스트·평가 결과서(9/8)와의 추적성을 확보하는 것을 목적으로 한다.

2.2 문서 범위 및 후속 산출물과의 관계


본 요구사항 정의서는 시스템이 제공해야 하는 기능·비기능 요구사항, 업무 규칙, 사용자 관점의 동작, 상태·예외 정책 및 수용 기준을 정의한다. 아키텍처, LangGraph 내부 구성, API DTO, DB 접근 구조, 트랜잭션·동시성 구현 방식, 인덱스·잠금 및 컴포넌트 구조는 시스템 설계서에서 정의한다.

시스템 설계 과정에서 기능 범위, 업무 규칙 또는 수용 기준의 변경이 필요한 경우 설계서에서 임의로 변경하지 않고 요구사항 정의서를 먼저 개정하며, 요구사항 추적 매트릭스를 함께 갱신한다. 단, 멘토 요구 항목인 Tool 명세, 기준정보 스키마, 문서셋, 판정 규칙 및 Text2SQL 질의셋은 추적성과 평가 기준 확보를 위해 본 문서에 포함한다.

2.3 시스템 개요

공정 흐름과 데이터

WAFER 처리 경로와 단계별 적재 테이블



모든 건수는 배포 CSV 실측값이다.

그림 1. 공정 흐름과 데이터 플로우 — WAFER 처리 경로와 단계별 적재 테이블

반도체 전공정 중 PHOTO·ETCH 2개 AREA의 장비 센서 데이터(FDC trace)를 WAFER 단위로 수집·요약하여 규칙과 이상감지 모델로 이상을 감지(Detection)하고, 발생한 알람에 대해 LangGraph 에이전트가 장비 관계(Neo4j)와 장비 매뉴얼(RAG)을 근거로 이상 유형을 분류·원인 분석·조치 권고(Classification)한다. 생산 영향이 큰 EQUIPMENT HOLD는 사람 승인(HITL) 후 전송하며, 자연어 질의(Text2SQL)와 React 기반 데이터 플랫폼으로 데이터 활용을 지원하고 전 과정을 감사로그로 기록한다.

[감지]	trace → 요약 → 규칙+모델 → 알람	(A)
[분류]	alarm_id → incident 집계 → 에이전트(Tool 3종: 요약/관계/문서) → 유형·원인·조치	(C, 근거는 A·B)
[승인]	EQP_HOLD → interrupt → 사람 승인 → 재개	(C + 화면)
[전송]	n8n → MES·메일 모의 전송 → 감사로그	(C)
[활용]	Text2SQL·통계·차트 / 감사로그 조회	(D)
[통합]	단일 FastAPI + 단일 React + Docker Compose	(공동, 통합 관리 C)


2.4 대상 독자

멘토, 프로젝트 팀원 4인, 과정 평가자

3. 용어 정의

도메인 구조

구역·공정·장비·챔버 계층 구조와 레시피·STEP·센서의 역할



그래서 판정 키가 세 개다 — (chamber_id, sensor_id, recipe_step_no). 같은 센서라도 STEP 이 다르면 다른 이야기이고, 챔버가 다르면 다른 장비 문제다.

그림 2. 도메인 구조 — 구역·공정·설비·챔버 계층 구조와 레시피·STEP·센서의 역할

용어	정의
FDC	Fault Detection and Classification. 이상 감지(규칙·모델)와 분류(에이전트)로 구성
OOS / OOC	Out of Spec(규격한계 이탈, 이상 확정) / Out of Control(관리한계 이탈, 경고)
LSL·LCL·TARGET·UCL·USL	센서별 5개 기준선. 관리한계(LCL/UCL)가 규격한계(LSL/USL) 안쪽에 위치
RECIPE STEP	공정 조건의 세부 단계(EXPOSE/DEVELOP, MAIN_ETCH/OVER_ETCH). FDC 판정 단위
FAULT CODE	이상 유형 4종: FOC(초점), RFM(RF정합), MFD(가스유량), TMD(척온도) + NRM(정상)
R03_CONSEC	동일 CHAMBER·SENSOR·RECIPE STEP에서 챔버 처리 순서상 연속 3 WAFER OOS 발생 시 챔버 이상 판정. chamber_wafer_cum ASC 기준으로 LOT 경계를 넘어 계산
HITL	Human-in-the-loop. EQP_HOLD를 사람 승인 후에만 전송하는 구조

용어	정의
Text2SQL	자연어 질문을 SQL로 변환하여 조회하는 기능. LLM은 계획 생성만, 실행은 코드
골든 시나리오	E2E 검증 시나리오 4건(자동조치/승인/반려/실패 처리). 4인 공동 책임. 상세는 부록 B
IN_CONTROL	DB 판정값 3종(IN_CONTROL·OOC·OOS) 중 정상. TROUBLE 문서 원문의 "IN_SPEC"은 본 문서에서 "모두 IN_CONTROL(= OOC/OOS 0건)"로 통일 표기 — OOC도 규격한계 안쪽이라 IN_SPEC만으로는 해석이 갈리기 때문

상세 용어는 배포 패키지 「00_용어집.pdf」를 따른다.

4. 시스템 범위

4.1 범위 내 (In Scope)

기능	범위
Detection	규칙 3종(한계선·연속) + 이상감지 모델 1종(IsolationForest), 배치 판정
Classification	이상 유형 4종 분류 + 원인 설명 + 조치 권고 (근거: 관계·문서)
문서 검색	기반구축에서 적재 완료된 md 문서 3종 청크·임베딩의 검증·검색 (bge-m3, pgvector)
관계 조회	Neo4j 기준정보 관계 조회 (상하류·형제 챔버)
조치	권고 생성 + n8n 경유 모의 전송(MES·메일). EQP_HOLD는 승인 후 전송
UI	React 기반 데이터 플랫폼과 FastAPI Backend를 구현한다. 기존 Streamlit 원안의 핵심 도메인 범위는 유지하되, 멘토링에서 확정한 조회 흐름에 맞춰 8개 화면으로 재구성한다
자연어 질의	Text2SQL(읽기 전용) + 통계·차트 계획
평가	이상감지 지표, 분류 품질, Text2SQL 정확도, Tool 계약 준수율·장애 처리, 자율성 Level 1·2 비교
통합	단일 FastAPI 앱(A·B·C·D Router) + 단일 React 앱 + Docker Compose 통합 실행 (5.5)

최종 화면 구성 (8개)




그림 3. 알람 대시보드 (/dashboard)




그림 4. 알람 목록·상세 (/alarms/:alarmId)




그림 5. 트레이스 뷰어 (/traces)

BISTelligence

FDC ANOMALY AGENT PLATFORM

1. 알람 대시보드

2. 알람 목록

3. 트레이스 뷰어

4. Agent 분석·승인

5. 조치 목록

6. 자연어 분석

7. 감사로그

Agent 분석·승인

저장된 실행 결과

RUN-20260603-0005

WAITING_APPROVAL

설비 PHO-01

행버 PHO-01-C1

파라미터 PH_FOCUS

LOT LOT-260007

기간 06-03 06:37 ~ 06:53

판정

FOC 초점 이상

PH_FOCUS 연속 OOS — CD_ADI 불량 유발

confidence 0.87

권고 조치

EQP_HOLD

심각도 HIGH

조치 근거가 제공되지 않았습니다.

승인 PENDING

APR-0002

결정자

사번 또는 이름

코멘트

결정 근거 (선택)

승인 반려

승인하면

approval PENDING → APPROVED

action 승인 APPROVED - 전송 WAITING

agent_run WAITING_APPROVAL → RUNNING

커밋 뒤 같은 thread_id 로 재개

Tool 호출

1 get_fdc_summary 412ms

2 get_equipment_context 388ms

3 search_documents 1,240ms

판단 근거

Agent 실행 응답에 저장된 근거만 표시

대표 FDC 요약

ALM-0019

대표 FDC 근거 없음

필터를 조정해 다시 조회해 주세요.

R03 연속 이상 근거

R03 근거 없음

해당 incident에 R03_CONSEC 근거가 없습니다.

설비 관계

Neo4j 관계 조회 Tool 결과

관계 근거 없음

필터를 조정해 다시 조회해 주세요.

상류 기어 근거

0건

상류 근거 없음

필터를 조정해 다시 조회해 주세요.

문서 검색 근거

0건

문서 근거 없음

필터를 조정해 다시 조회해 주세요.

부분 실패

0건

Tool 오류 없음

필터를 조정해 다시 조회해 주세요.

그림 6. Agent 실행·승인 (/agent-runs/:runId)

BISTelligence

FDC ANOMALY AGENT PLATFORM

1. 알람 대시보드

2. 알람 목록

3. 트레이스 뷰어

4. Agent 분석·승인

5. 조치 목록

6. 자연어 분석

7. 감사로그

조치 목록

incident 단위 · 기간 내 10건

기간 2026-06-01 ~ 06-04

공정 전체

설비 전체

조치 전체

승인 대기 2

전송 실패 0

진행 중 0

완료 8

전체 10

기본은 승인 대기 — 사람이 볼 게 먼저

조치

조치 시각 내림차순

조치	incident	파라미터	조치 코드	심각도	승인	전송	알람	시각	
ACT-0010 생성 실행 →	LOT-260010 · ETC-01-C1 LOT · 행버	ET_CF4	EQP_HOLD	HIGH	승인 대기	WAITING	6건	06-04 07:11	검토 →
ACT-0005 생성 실행 →	LOT-260007 · PHO-01-C1 LOT · 행버	PH_FOCUS	EQP_HOLD	HIGH	승인 대기	WAITING	6건	06-03 06:39	검토 →

그림 7. 조치 목록 (/actions)

8




그림 8. 자연어 분석 (/analytics)




그림 9. 감사로그 (/audit-logs) — 지면 관계상 이력 상단부만 표시

화면	담당	주요 기능
알람 대시보드	A+C	적용 기간·계층 필터, 알람 추이, 파라미터 TOP5, 설비별 건수, 승인 대기 목록, 최근 알람
알람 목록·상세	A+C	필터·이상값·Agent 원인·조치·근거
트레이스	A	AREA·설비·챔버·파라미터·레시피·LOT·WAFER·기간 조건, 다중 센서 시계열과 한계선 오버레이
조치 목록	C	조치·승인·전송 상태 필터와 Agent 실행 상세 연결
Agent 실행·승인	C	실행 상태·판단 근거·권고 조치·승인·반려·전송 결과
Knowledge	B	Neo4j 관계·RAG 문서 검색·근거 원문
Analytics	D	자연어 질문·SQL·표·통계·동적 차트·질의 이력
감사로그	D	Agent·Tool·승인·전송·자연어 질의의 감사 이력 조회·검색·통계

알람 상세는 `/alarms/:alarmId`로 같은 알람 화면 안에서 상태를 복원하므로 별도 화면으로 세지 않는다. 조치 목록과 Agent 실행·승인은 조회 목적이 달라 각각 독립 화면으로 두며, Knowledge는 Agent 화면에서 일부 근거를 재사용하더라도 독립 조회 화면을 유지한다.

4.2 범위 외 (Out of Scope)

실시간 스트리밍 / 실제 장비 제어(PLC·SCADA) / 대화형 챗봇 / PDF 파싱 / SPC 관리도 운영 / APC / RMS / 사용자 인증·권한 / 클라우드·Kubernetes 배포 / 실시간 WebSocket / 멀티에이전트 / 웨이퍼 맵·die 단위 분석 / Text-to-Cypher / 다단계 승인·결재선 / 승인 요청 자동 만료 스케줄러 / 여러 모델 앙상블 / ML 예측의 `fdc_alarm` 추가 생성 / 새로운 이상 유형 자동 발견 / 이미지·도면 검색 / 온톨로지 정의·추론 엔진 / 전송 완료 후 추가 알람에 따른 순차 조치 재상향 (배포 가이드 03 「하지 않는 것」 및 IV장 준수)

※ FR-A-09(피처 확장·비교 실험)는 단일 모델의 개선 실험으로 도전 과제이며, 범위 외인 "여러 모델 앙상블"과 구분한다.

※ UI 구현 기술은 멘토 원안의 Streamlit에서 FastAPI Backend와 React Frontend 구조로 전환한다. 본 변경은 2026.07.31 멘토링을 통해 확정하였다.

4.3 전제 및 가정

- 데이터는 공정 물리 특성을 반영한 합성 데이터이며 배포 패키지 원본을 수정 없이 사용한다
- 이상감지는 실시간이 아닌 WAFER 처리 완료 후 배치 판정이다
- 단일 사용자를 가정하며 인증·권한 관리는 구현하지 않는다 (decided_by 한계는 10장 참조)
- 개발 DB와 Neo4j·n8n은 교육장 공용 개발 서버를 사용하며, 실제 접속 정보는 각 팀원의 .env로 관리한다. 스키마·데이터는 배포 SQL로 적재된 상태를 기준으로 한다
- PostgreSQL·Neo4j·n8n 실행과 데이터·관계·문서 임베딩 최초 적재는 완료되었다(기반구축). 최초 기반구축은 다시 수행하지 않으나, FastAPI·React를 포함한 최종 Docker Compose 통합은 수행한다(FR-I-04)
- LLM은 KOSA 지급 API 키를 사용한다(2026.07 합의, 배포 기본값 Ollama 대체). 제공자 전환이 가능하도록 .env로 추상화하며, 실제 사용 모델명은 `agent_run.llm_model`에 기록한다

5. 기능 요구사항

ID: FR-{도메인}-{번호} · 우선순위: 필수(합격선) / 권장(목표) / 도전(스트레치) 수용 기준은 "검증 가능한 문장"으로 기술하며 테스트·평가 결과서(9/8)에서 재사용한다. 각 담당자는 자기 기능의 DB·AI 로직 → Service → FastAPI Router → Pydantic Schema → React 화면 → 실제 API 연결 → 테스트 → 평가까지 책임진다(풀스택 기능 책임제).

5.1 Detection — 담당: 신동원 (A)

ID	명칭	설명	우선순위	수용 기준
FR-A-01	요약 재계산	fdc_trace를 WAFER×SENSOR×RECIPE STEP 단위로 집계하여 평균, 표본표준편차(ddof=1), 최소, 최대, point_cnt, ooc_point_cnt, oos_point_cnt 및 judgement를 계산	필수	PK(lot_hist_id, sensor_id, recipe_step_no) 기준 1,600건 일치 / point_cnt·ooc_point_cnt·oos_point_cnt·judgement 완전 일치 / 숫자형 집계값 허용 오차 0.0001 이하
FR-A-02	규칙 판정	R01_OOS·R02_OOC·R03_CONSEC 3종 구현. R03_CONSEC는 판별 키 (chamber_id, sensor_id, recipe_step_no), chamber_wafer_cum ASC 기준으로 LOT 경계를 넘어 계산한다. OOS가 아닌 판정에서 연속 횟수를 초기화(재무장)하며, 연속 횟수가 최초 3에 도달할 때만 알람을 1회 생성한다. ET_REFL은 상한만 판정. 알람 재현은 규칙 기반 판정 결과로만 검증(ML 결과와 분리)	필수	R01 34 / R02 14 / R03 3, 전체 51건 동일 재현. R03는 ALM-0008-0022-0048과 발생 위치가 일치하고, 연속 4 WAFER 이상에서도 정상 복귀 전까지 추가 R03를 생성하지 않는다. 동일 WAFER·SENSOR의 R01_OOS와 R03_CONSEC는 별도 알람 행으로 계수한다
FR-A-03	이상감지 모델	IsolationForest 학습·저장(joblib). 요약통계 입력. anomaly_score와 정상·이상 예측을 규칙 알람과 분리하여 생성한다. 초기 필수 범위에서는 ML 결과를 fdc_alarm에 추가 적재하지 않으며, 알람 51건·incident 10개·조치 10건 기준은 규칙 판정만으로 유지한다. ML 기반 알람 생성은 범위 밖이다. lot_history.fault_code는 모델 평가 정답으로만 사용하며 Agent 판단 입력에 포함하지 않는다(데이터 누수 방지)	필수	모델 파일 생성 / ML 실행 전후 fdc_alarm 행 수 51건 불변 / 동일 LOT의 WAFER가 학습·평가에 섞이지 않도록 lot_id 기준으로 분리하고 random_state를 고정하여 fault_code != 'NRM' 기준 Precision·Recall·F1 산출 / 성능 목표는 P·R·F1 각 0.80 이상으로 하되 목표 미달만으로 필수 기능 미완료로 판정하지 않고 원인·개선 결과를 평가 보고서에 기록 / 2차 보조: metrology.judgement 연관성 확인(계측 40건뿐이므로 보조 지표)
FR-A-04	anomaly_score 산출	0~1 정규화 점수. 정규화 공식·모델 버전·임계값 산정 근거를 기록하며, 정규화 통계는 학습 데이터에서만 계산	필수	.env 임계값(0.62/0.80)과 동일 축으로 C에 전달, 동일 입력 동일 점수
FR-A-05	Tool: get_fdc_summary	센서 요약(value_mean·value_std·value_min·value_max)+한계선 5개+anomaly_score 반환 (6.1)	필수	잘못된 ID에도 ok:false 반환, 예외 미발생

ID	명칭	설명	우선순위	수용 기준
FR-A-06	알람·대시보드·Trace API	알람 대시보드 요약, 알람 목록·상세, Trace 카탈로그·다중 검색 API(11.3)를 제공한다. 모든 집계는 SQL·규칙으로 계산하며 LLM을 사용하지 않는다. 대시보드 요약 API는 <code>date_from-date_to-area-equipment_id-chamber_id</code> 필터를 지원하고, 실제 적용 기간 <code>date_range</code> 와 기간 내 최신 데이터 일자 <code>reference_date</code> , 알람·OOS/OOC 수, 일별 추이, 파라미터 TOP5, 설비·챔버별 건수, 승인 대기 목록, 최근 알람을 반환한다. 기간을 모두 생략하면 선택한 계층 범위에서 알람이 존재하는 최소·최대 일자를 자동 적용하고 최신 일자를 <code>reference_date</code> 로 반환하며, 한쪽 경계만 생략하면 해당 범위의 데이터 경계로 보완한다. 알람 목록 API는 <code>date_from-date_to-area-equipment_id-chamber_id-sensor_id-rule_id-judgement</code> 를 AND 조건으로 적용한다. <code>GET /traces/catalog</code> 는 필터 선택지와 센서 한계선을, <code>POST /traces/search</code> 는 JSON body의 센서·WAFER 다중 조건과 기간에 맞는 시계열·한계선·구간 통계를 반환한다. 승인 대기 목록은 C의 승인 조회 API 또는 공유 ApprovalService를 재사용하고 A가 승인 로직을 중복 구현하지 않는다. 세부 산식은 아래 「대시보드 집계·필터 확정 규칙」을 따른다	필수	전체 계층·기간 자동 적용 시 <code>date_range=[2026-06-01, 2026-06-04]</code> , <code>reference_date=2026-06-04</code> , 알람 51건·OOS 37건·OOC 14건으로 기준 SQL과 일치 / 일별 추이 합계와 설비별 건수 합계가 필터된 알람 수와 일치 / 파라미터 TOP5가 <code>alarm_count DESC</code> , <code>sensor_id ASC</code> 기준 SQL과 일치 / 최근 알람 5건이 <code>occurred_at DESC</code> , <code>alarm_id DESC</code> 와 일치 / 승인 대기 목록이 C 조회 결과와 일치하고 대시보드 기간·계층 필터에 의해 누락되지 않음 / 알람 단일·복합 필터와 기간 경계값이 기준 SQL과 일치 / Trace 카탈로그 선택지·다중 센서·다중 WAFER 검색·한계선 5종 표시가 기준 데이터와 일치 / <code>ET_REFL</code> 은 <code>upper_only=true</code> 이며 하한선이 렌더링되지 않음 / LLM 미호출 확인
FR-A-07	알람·대시보드·Trace 화면	알람 대시보드는 적용 기간과 AREA→설비→챔버 계층 필터, 승인 대기 목록, 알람 추이, 파라미터 TOP5, 설비별 건수, 최근 알람을 표시한다. 최초 진입은 기간 경계를 보내지 않고 서버가 반환한 <code>date_range-reference_date</code> 를 사용하며 날짜를 화면 상수로 고정하지 않는다. 필터 변경 시 서버 집계 결과로 모든 카드·차트·목록을 갱신한다. 알람 목록·상세는 URL로 선택 상태를 복원하고 Trace로 이동할 수 있어야 한다. Trace 화면은 카탈로그에서 AREA·설비·챔버·파라미터·레시피·LOT·WAFER를 선택하고 여러 센서·WAFER의 시계열을 기간 기준으로 비교하며 센서 한계선을 겹쳐 표시한다	필수	최초 진입 시 <code>2026-06-01~2026-06-04</code> 기간과 <code>reference_date=2026-06-04</code> 가 표시되고 기간 전체 알람 51건 집계가 비어 있지 않음 / 계층·기간 필터 변경 시 추이·TOP5·설비별 건수·최근 알람이 실제 API 결과로 갱신 / 승인 대기 항목 선택 시 해당 Agent 실행 화면으로 이동 / 최근 알람 선택 시 알람 상세 복원 / Trace에서 파라미터·WAFER 다중 선택과 Empty 상태 동작 / <code>upper_only=true</code> 센서는 하한선 미표시 / Loading·Error·Empty·Success 상태 구분
FR-A-08	(결번 — FR-C-12로 이동)	n8n 알람 워크플로는 v9.3 8장 확정에 따라 C 소유. 2.3 다이어그램 [전송] (C)와 정합	—	—
FR-A-09	모델 고도화	피쳐 확장·비교 실험	도전	비교표 산출

A 확정 사항: R03_CONSEC 규칙은 FR-A-02-8.1에 확정 반영됨 — 판별 키 (`chamber_id`, `sensor_id`, `recipe_step_no`), `chamber_wafer_cum ASC`, LOT 경계 통과, 임계점 1회 발행·재무장. 운영 데이터에서 `chamber_wafer_cum` 중복 시 보조 정렬 키·상태 저장 방식만 시스템 설계서에서 정한다.

대시보드 집계·필터 확정 규칙

- 시간 기준은 NFR-13의 Asia/Seoul이다. 기간 경계를 모두 생략하면 선택한 `area-equipment_id-chamber_id` 범위의 `fdc_alarm` 최소·최대 일자를 `date_range=[시작일, 종료일]`로 적용하고 그 범위의 최신 데이터 일자를 `reference_date`로 반환한다. 한쪽

경계만 지정하면 생각한 경계를 해당 계층의 데이터 최소·최대 일자로 보완하며, `date_from > date_to`는 입력 오류다

- AREA는 `fdc_alarm.chamber_id` → `dim_chamber.area_id`로 판별한다. 알람 수는 적용 기간·계층 범위의 `fdc_alarm` 행 수, OOS·OOC 수는 각각 `judgement='OOS'`, `judgement='OOC'`인 알람 행 수다. 한 WAFER의 복수 규칙 알람은 각각 계수한다
- 일별 추이는 `date_range`의 날짜별 OOS/OOC 알람 행 수와 R03_CONSEC 존재 여부를 반환한다. 적용 기간 전체의 일별 합계는 같은 필터의 OOS/OOC 총계와 일치해야 한다
- 파라미터 TOP5는 같은 범위에서 `sensor_id`별 알람 행 수를 집계하여 `alarm_count DESC`, `sensor_id ASC`로 정렬한 상위 5개다. 5종 미만이면 존재하는 파라미터만 반환한다
- 설비별 건수와 그 하위 챔버별 건수는 같은 기간·계층 필터를 적용하며, 설비별 합계는 해당 필터의 전체 알람 수와 일치해야 한다
- 최근 알람은 같은 기간·계층 범위에서 `occurred_at DESC`, `alarm_id DESC` 상위 5건이다
- 승인 대기는 기간·계층 필터와 무관한 전체 `approval_request.status='PENDING'` 목록이며 C API 또는 공유 ApprovalService 결과를 사용한다
- 계측 PASS율과 챔버 상태 카드는 알람 대시보드 범위에서 제외한다. 계측 통계가 필요하면 D Analytics 자연어 질의를 사용한다
- Trace 한계선의 `upper_only`는 DB 스키마 컬럼을 추가하지 않고 센서 도메인 규칙으로 계산한다. 반사파 센서 `ET_REFL`은 `upper_only=true`로 반환해 `spec_lower_ctrl_lower`를 렌더링하지 않으며, 기존 배포 스키마 파일은 수정하지 않는다

5.2 Knowledge — 담당: 강연권 (B)

기반구축(완료: Neo4j 최초 적재, 장비 문서 최초 임베딩 적재)과 B의 개발 책임(적재 결과 검증, Cypher 관계 조회, pgvector 검색, Tool-API-React 화면, 검색 품질 평가)을 구분한다.

ID	명칭	설명	우선순위	수용 기준
FR-B-01	Neo4j 기준정보 적재 확인	master.cypher 기반 적재 검증	필수	노드 총 24개, 관계 총 26개가 master.cypher 결과와 일치, UPSTREAM_OF 관계 조회 성공
FR-B-02	문서 청크·임베딩 검증	기반구축에서 적재 완료된 청크·임베딩 검증(###/### 경계·120~1,200자 청킹 규칙, 제목 접두어 방식). 재적재가 필요해질 경우의 파이프라인 유지보수는 B 책임	필수	document 3건 / document_chunk 39건(배포 원본 문서·적재 스크립트 무변경 기준 기대값 13+12+14. 상이 시 중복 적재·원본 변경 신호로 취급하고 원인 확인) / embedding IS NULL 0건 / 임베딩 차원 1024 / 청크 길이 120자 미만·1,200자 초과 각 0건 / model_code 필터 시 COMMON 포함 / 제목·절 제목 접두어 임베딩 확인
FR-B-03	Tool: get_equipment_context	챔버의 장비·구역·공정 + 형제 챔버 + 상하류 반환 (6.2)	필수	PHO-01-C1 조회 시 downstream에 ETC-01 포함
FR-B-04	Tool: search_documents	벡터 검색 top_k, model_code 필터 시 COMMON 자동 포함 (6.3)	필수	고정 시험 질문 3종("반사파가 올라가면 무슨 문제인가" / "포커스가 벗어나면 CD가 어떻게 되나" / "장비를 세우려면 승인이 필요한가", 가이드 03 원문)에서 관련 절 상위 반환
FR-B-05	임베딩 모델 싱글턴	동일 API 프로세스 생명주기에서 임베딩 모델은 1회만 생성하며, 이후 요청은 동일 모델 인스턴스를 재사용	필수	단위 테스트 또는 초기화 로그로 모델 생성 횟수가 1회임을 확인한다(지연시간 감소는 OS 캐시 영향으로 재현성이 없어 참고 지표로만 사용)
FR-B-06	관계·근거 API·화면	관계 그래프 조회 API + React 관계 뷰, 문서 근거 표시	필수	관계도 시각화 렌더링

ID	명칭	설명	우선순위	수용 기준
FR-B-07	검색 품질 평가	RAG 골드셋(질문/기대 문서/기대 질 제목/복수 정답 허용 여부/허용 top_k)과 관계 조희 골드셋으로 평가	필수(v9.3 완료 기준에 따라 권장→필수 상향)	문서 검색 골드 10문항 이상에서 Recall@4 $\geq$ 0.80, MRR $\geq$ 0.70 / 관계 골드셋 6건(챔버 4건 <code>get_equipment_context</code> + 장비 2건 <code>/relations/equipment</code>)에서 정확도 100%. PHO-01-C1의 하류 존재와 ETC-01-C1의 하류 없음·상류 존재 경계를 모두 포함
FR-B-08	하이브리드 검색	pg_trgm 키워드 + 벡터 결합	도전	센서 ID 질의 정확도 개선 확인

5.3 Agent·HITL — 담당: 방대혁 (C)

ID	명칭	설명	우선순위	수용 기준
FR-C-01	LangGraph 에이전트	State·노드·분기 구성. API·화면에서 <code>alarm_id</code> 1건을 입력받으면 해당 알람이 속한 (<code>lot_id</code> , <code>chamber_id</code>) incident 전체를 조회하여 유형·원인·조치를 생성한다. 자동 배치와 수동 실행 모두 incident당 agent_run 1건을 생성하며, <code>agent_run.alarm_id</code> 에는 결정론적으로 선택한 대표 알람을 기록한다	필수	입력 alarm_id가 속한 incident 전체의 알람을 근거로 유형·원인·조치·근거가 agent_run 1건에 기록 / 대표 alarm_id와 포함 alarm_ids를 추적 가능 / 시나리오 매핑은 부록 A·B
FR-C-02	자율성 레벨 스위치	동일 Tool·State로 Level 1(고정)·2(분기) 전환. 3(ReAct)은 도전	필수(1·2)	.env 변경만으로 전환 동작 / 동일한 고정 시나리오 집합에서 Level 1·2 모두 정상 완료하고 완료율·평균 Tool 호출 수·지연시간·토큰 사용량을 비교 기록(성능 하한은 두지 않음)
FR-C-03	decide_action	규칙 기반 조치 결정. 우선순위 R03→OOS3+→OOS1~2→OOC, 상향·하향 조건 반영. LLM 위임 금지	필수	8.2 결정표 단위 테스트 전부 통과
FR-C-04	HITL 승인 흐름	EQP_HOLD 시 approval_request 생성 + interrupt(PostgreSQL Checkpoint), 승인 후 thread_id 재개	필수	골든 시나리오 2·3 통과 (부록 B)
FR-C-05	승인 API	승인/반려 단일 API. 요청 본문에 decided_by·decision_comment 포함(승인 감사 추적 요구(8.3·11.1)와 직결). 조건부 UPDATE로 이중 처리 차단(409, EXPIRED 포함). 승인 시 <code>approval_request.decided_by/decided_at</code> 을 기존 <code>action_history.approved_by/approved_at</code> 에 동기화하며, 반려 시 승인자 필드는 NULL로 유지한다. 승인 요청 자동 만료 스케줄러는 범위 밖이며, EXPIRED는 기존·테스트 fixture의 터미널 상태를 재처리하지 않는 방어 규칙으로만 지원한다	필수	동일 건 재승인 요청 시 409 / EXPIRED 요청의 승인·반려 시 409이고 관련 상태·이력 변경 없음 / 승인자의 decided_by·decided_at과 action_history.approved_by·approved_at 일치 / 반려 행의 approved_by·approved_at NULL

ID	명칭	설명	우선순위	수용 기준
FR-C-06	Tool: send_action	action_id 기반 먹등 전송 (6.4). SENT 재호출뿐 아니라 HTTP 응답 유실·timeout 후 동일 action_id가 재시도되는 경우에도 MES·메일 모의 전송 효과는 최대 1회만 발생해야 한다	필수	정상 중복 호출과 응답 유실·timeout 재시도에서 동일 action_id의 실제 전송 효과가 각각 1회만 발생
FR-C-07	실행 기록	agent_run의 llm_model·latency_ms는 성공·실패 모두 필수 기록하고, input/output_tokens는 제공자가 반환할 때 기록한다. latency_ms는 LLM·Tool·코드의 실제 처리시간 합계로 정의하며 HITL 사람 대기시간은 제외한다. Agent 흐름에서 수행한 A·B·C Tool 호출은 agent_tool_call에 전부 기록한다	필수	실행 1건당 기록 조회 가능 / llm_model·latency_ms NULL 없음 / HITL 대기 전후 측정에서도 사람 대기시간이 latency_ms에 포함되지 않음
FR-C-08	호출 상한·재시도	AGENT_MAX_TOOL_CALLS=8, AGENT_MAX_RETRY=3 (.env.example 기준 변수, 의미 정의는 8.5). Tool 실패 시 그래프가 생존해야 하며, 조치를 생성할 수 있는 실행은 진단 단계에서 최초 send_action 1회분을 소진하지 않도록 보장한다. 호출 수는 HITL 중단·재개와 checkpoint 유실 복구 전후를 합산한다	필수	골든 시나리오 4-A·4-B 통과 / 선택 진단이 있어도 최초 전송 1회가 가능하고 전체 호출 8회 이하 / HITL-checkpoint 유실 복구 후 호출 수 초기화 없음 / 전송 재시도는 남은 총예산 안에서만 수행
FR-C-09	배치 트리거	자동 배치는 미처리 알람을 (lot_id, chamber_id)로 묶고 incident당 대표 alarm_id 1건·agent_run 1건으로 신규 처리한다. incident 처리를 시작하면 포함된 모든 alarm_id를 해당 실행의 처리 대상으로 확정하며, 완료·승인 대기·실패 여부와 관계없이 다음 자동 배치에서 중복 선택하지 않는다. 실행 이력이 있는 incident는 건너뛴다(FAILED 포함 — 자동 재선택 금지). 이전 실행의 최신 상태가 FAILED인 경우 화면에서 명시적 수동 재실행만 가능하다. 수동 API에 전달된 alarm_id도 해당 incident로 해석하며, RUNNING 또는 WAITING_APPROVAL 실행이 존재하면 409 INCIDENT_ALREADY_RUNNING, COMPLETED이면 409 INCIDENT_ALREADY_PROCESSED로 응답한다(자동 배치는 HTTP가 아니므로 응답 코드 없이 건너뛴). 전송 실패로 action_history.send_status=FAILED인 기존 조치가 있으면 수동 재실행에서도 동일 action_id를 재사용하고, 전송 이전 실패로 action_history가 없을 때만 신규 조치를 생성한다	필수	최초 incident 자동 실행 / incident당 agent_run 1건 / 실행 이력 보유 incident 배치 제외 / FAILED incident 자동 재실행 안 됨 / FAILED incident 수동 재실행 / 진행 중 incident 수동 재실행 409 / COMPLETED incident 수동 재실행 409·신규 run 0건 / 동일 데이터로 자동 배치를 즉시 재실행할 때 신규 Agent 실행·조치·전송 각 0건 / 전송 실패 수동 재실행 시 동일 action_id 유지

ID	명칭	설명	우선순위	수용 기준
FR-C-10	연쇄 이상 판단	TROUBLE 4.1 판별 절차로 순수 연쇄 이상과 복합 이상을 구분한다. 순수 연쇄 이상은 하류 조치를 생성하지 않고, 복합 이상은 하류 자체 조치를 유지하면서 상류 기여를 함께 제시한다. 시스템 실행 트리거는 FR-C-09의 alarm_id이다. 연쇄 이상 진단의 시작 조건은 CD_AEI FAIL이며, CD_ADI FAIL은 상류 PHOTO 기여를 확인하는 근거로 사용한다. ALM-0031 E2E에서는 다른 WAFER의 CD_AEI FAIL을 실행 트리거가 아닌 LOT 문맥 근거로만 활용한다	필수(핵심 차별 기능, 권장→필수 상향)	[복합 이상 · 단독 E2E] 빈 Agent E2E DB에서 LOT-260008 PHOTO incident를 먼저 처리하여 expected fixture ACT-0007에 대응하는 신규 LOT_HOLD 조치를 생성한 뒤 ALM-0031(LOT-260008-ETC-01-C1-ET_CF4 R02_OOC)을 실행한다. ETCH 조치를 MONITOR로 결정하고, get_equipment_context(UPSTREAM_OF)와 같은 LOT의 PHOTO FOC·선행 생성 LOT_HOLD 조치 및 CD_ADI/CD_AEI FAIL을 상류 기여 근거로 제시한다. ACT-0007은 DB에 미리 적재하지 않고 비교용 expected fixture로만 사용하며, PHOTO LOT_HOLD 중복 미생성·하류 ETCH EQP_HOLD 미적용을 확인한다. [전체 배치] 51건 자동 배치에서도 incident 처리 순서와 관계없이 ALM-0031 분석 결과에 상류 PHOTO LOT_HOLD 판단 근거가 포함된다. [순수 연쇄 · 단위 테스트] ETCH 센서 4종 모두 IN_CONTROL(=OOC/OOS 0건) + 같은 WAFER PHOTO OOS 조건에서 decide_action이 하류 조치를 생성하지 않고 recommended_action=NULL 반환 (해당 케이스 LOT-260008 w1은 트리거 알람이 없어 E2E 불가 — 골든 시나리오 미포함)
FR-C-11	Level 3 ReAct	완전 자율 루프 + 레벨별 비교	도전	비교표 산출
FR-C-12	n8n 알림 워크플로	/webhook/equipment-alert 수신 → 메일·MES 모의 발송 (구 FR-A-08, v9.3 8장 확정에 따라 C로 이동. send_action(FR-C-06)의 전송 하류 구성요소). action_id를 역등 키로 사용하여 동일 요청의 downstream 효과를 중복 실행하지 않는다	필수	골든 시나리오 1·2에서 전송 확인 / 동일 action_id 중복·timeout 재시도에서도 모의 발송 효과 1회
FR-C-13	조치 목록·Agent 실행·승인 화면	조치 목록과 Agent 실행 상세를 분리한다. 조치 목록은 승인·전송·조치 코드·설비·챔버·기간 필터를 제공하고, 항목 선택 시 해당 Agent 실행 상세로 이동한다. Agent 실행 화면은 실행 상태와 Fault Code·원인·조치·센서·관계·문서 근거를 표시하며 PENDING 승인 요청의 승인·반려와 전송 결과를 처리한다	필수	조치 목록에서 승인 대기·전송 실패 필터 및 Agent 실행 이동 / Agent 실행 목록·상세 조회 / PENDING 승인 요청 실제 API 승인·반려 / 기처리·EXPIRED 건 409 표시 / 조치 전송 성공·실패 상태 확인

ID	명칭	설명	우선순위	수용 기준
FR-C-14	조치 중복 방지	자동 배치는 (lot_id, chamber_id)가 동일한 알람을 하나의 incident로 묶어 전체 알람을 먼저 집계한다. 동일 incident에 여러 센서·규칙 알람이 존재하면 8.2 결정표에서 가장 높은 우선순위의 조치 1건만 생성·전송한다. Agent 실행과 조치 이력은 각각 incident당 1건이며, 조치가 확정되는 시점에 action_history 행을 생성한다. 자동 조치는 approval_status=AUTO, send_status=WAITING, approved_by='system', approved_at=created_at, EQP_HOLD는 approval_request와 함께 approval_status=PENDING, send_status=WAITING, approved_by=NULL, approved_at=NULL로 생성하며, 승인·반려 시 새 행을 만들지 않고 기존 행을 갱신한다. 전송 완료 이후 추가 알람이 유입되어 기존 조치를 다시 상향하는 순차 incident 처리는 초기 프로젝트 범위에서 제외한다. incident에 포함된 모든 alarm_id의 처리 완료·소속 관계 저장 방식과 대표 alarm_id 선택 규칙은 시스템 설계서에서 정한다	필수	action_history-agent_run-agent_run_alarm-agent_tool_call-approval_request-audit_log-action_delivery-운영 nl_query_log-Checkpoint 실행 데이터가 빈 Agent E2E DB에서 알람 51건 처리 시 agent_run 10건과 신규 action_history 10건이 생성되어 (lot_id, chamber_id) 10개 incident와 각각 1:1 대응한다. 승인 결정 전 EQP_HOLD 3건은 PENDING/WAITING이며 approval_request 3건이 PENDING으로 생성된다 / 별도 expected fixture ACT-0001~0010의 조치 코드와 전부 일치 / LOT-260005 알람 5건 → agent_run-LOT_HOLD 각 1건 / LOT-260004 R01-R03 6건 → agent_run-EQP_HOLD 각 1건 / 동시 실행에서도 중복 실행·생성·전송 없음 / 동일 데이터로 두 번째 자동 배치 실행 시 신규 Agent 실행·조치·전송 각 0건
FR-C-15	Fault Code 분류 평가	런타임 자동 배치의 실행 단위(FR-C-01-09-14: incident당 agent_run 1건)와 별도로, 동일 분류 로직의 오프라인 고정 평가 집합은 fdc_alarm 51개 행으로 구성한다. 각 평가 alarm_id도 런타임과 동일한 incident 문맥 생성 로직을 사용하되 결과를 agent_run에 적재하지 않는 평가 모드로 실행한다. 각 알람과 연결된 lot_history.fault_code를 정답 라벨로만 사용하여 FOC·RFM·MFD 분류 품질을 측정한다. 정답 라벨은 분류 입력·프롬프트·Tool 결과에 포함하지 않는다. 동일 WAFER의 복수 알람도 각각 평가 표본 1건으로 계수하며, TMD는 배포 표본 0건이므로 TROUBLE 3.4 기반 합성 fixture로 별도 검증한다. 평가 모델·프롬프트·temperature 등 실행 설정을 함께 기록한다	필수	오프라인 표본 51건 전부 평가(FOC 22 / RFM 15 / MFD 14 / NRM 0) / agent_run 추가 생성 0건 / Accuracy-클래스별 Precision-Recall-F1-Macro-F1-혼동행렬 산출 / Accuracy-Macro-F1 각 0.80 이상을 비강제 성능 목표로 설정 / 목표 미달만으로 필수 기능 미완료로 판정하지 않되 원인·개선 계획 기록 / TMD 합성 fixture 분류 성공 / 정답 라벨 입력 누수 없음

C 확정 사항: 여러 LOT 반복·하류 공정 전파·정상 복귀의 판별 기준과 상향 상한 및 충돌 우선순위는 8.2 결정 규칙으로 확정하며, 조건별 단위 테스트와 배포 51알람→10incident→10조치 전수 재현으로 검증한다.

FR-C-09 배치 실행 범위: 초기 필수 범위에서 "자동 배치"는 incident 선택·집계·중복 방지·Agent 실행을 사람의 건별 판단 없이 처리한다는 뜻이다. 실행 진입점은 관리 명령을 명시적으로 1회 호출하는 방식으로 확정하며, 스케줄러·상시 폴링은 후속 확장 범위로 둔다.

5.4 Analytics — 담당: 천승현 (D)

ID	명칭	설명	우선순위	수용 기준
FR-D-01	Tool: generate_analys_plan	자연어 → {sql, metric, group_by, visualization} 구조화 출력 (6.5). 독립 Analytics Tool로 구현하며 LangGraph 연결은 스트레치 범위	필수	골드 질문셋에서 스키마 유효 JSON 반환
FR-D-02	SQL 검증	sqlglot 파싱: 단일 SELECT만, 다중 문장 차단, 테이블·컬럼 화이트리스트, 시스템 카탈로그 접근 차단, 위험 함수 차단, LIMIT 500 강제. 읽기 의도의 구문·스키마·컬럼 불일치는 최초 생성 후 교정 재생성 1회만 허용한다(총 2회 시도). 쓰기 요청·다중 문장·비허용 테이블·위험 함수·시스템 카탈로그 등 정책 위반은 재생성 없이 즉시 거부한다. 재생성 SQL도 동일 검증을 통과해야 하며 실패 시 실행하지 않는다. Tool 경계에서는 {ok:false, reason}으로 반환하고, REST POST /analytics/query의 정책 거부는 조회 결과의 한 종류로 HTTP 200과 is_valid=false, is_rejected=true, reject_reason을 반환해 화면이 실행 오류와 구분하게 한다. 요청 JSON 누락·타입·길이 오류처럼 분석을 시작할 수 없는 malformed 요청만 HTTP 422다. 이 제한은 Agent의 AGENT_MAX_RETRY와 별개다	필수	9.2 방어 케이스 6종 전부 안전하게 차단·처리 / 교정 가능 오류는 최대 1회 재생성 후 성공 또는 안전 실패 / 정책 위반은 재생성·SQL 실행 0회·HTTP 200 구조화 거부 응답·nl_query_log.is_rejected=true 기록 / malformed 요청은 422
FR-D-03	읽기 전용 실행	운영 자연어 질의는 승인·조치 등 전용 화면과 같은 현재 운영 데이터 상태의 16개 허용 테이블을 kosa_readonly로 조회하고 statement_timeout 5s를 적용한다. 골드 평가는 운영 DB가 아니라 배포 초기 상태를 유지한 별도 Text2SQL 평가 DB에서 같은 권한·정책으로 실행한다. DB 내부 오류·접속정보는 노출하지 않는다	필수	운영 /analytics/query의 action_history 결과가 전용 화면이 사용하는 운영 DB의 현재 값과 일치 / 평가 실행은 운영 상태를 변경하거나 참조하지 않음 / 쓰기 시도 DB 레벨 거부
FR-D-04	결과 표·통계·차트	실행 결과를 표+metric 통계+동적 차트(bar/line/histogram)로 반환	필수	차트 호환성 규칙(8.4) 위반 시 규칙대로 강등
FR-D-05	질의 이력 기록	nl_query_log에 실제 스키마 필드만 기록: question, generated_sql, is_valid, is_rejected, reject_reason, row_cnt, latency_ms, error_msg	필수	성공·실패 모두 기록 (성공 여부는 is_valid-is_rejected-error_msg 조합으로 판별)
FR-D-06	자연어 분석 화면	질문 입력 → 생성 SQL 확인 → 표·통계·차트와 자연어 질의 이력 조회·재실행 (React)	필수	정상 결과·정책 거부·실행 오류를 구분 표시 / 이력에서 과거 질문 재실행 / E2E 시연 가능
FR-D-07	감사로그 조회 API·화면	이벤트 유형·주체·기간 필터, 상세 JSON 펼침, 유형별 통계	필수	A·C가 기록한 이벤트(11.1 이벤트 9종)가 화면에 표시
FR-D-08	Text2SQL 평가	9장의 골드 질문셋과 채점 규칙으로 실행 결과·정렬·시각화 계획 정확도를 평가	필수	골드 12건 중 10건 이상 정답(≥83%) / 정수·문자열·ID 정확 비교 / 실수 절대오차 0.001 / 정렬 요구 문항만 순서 비교 / 시각화 문항은 결과+chart_type-x-y 비교 / 방어 6종 6/6 안전 처리
FR-D-09	SQL 재검증 API	사용자가 수정한 SQL 재검증	권장	검증 사유 반환

ID	명칭	설명	우선순위	수용 기준
FR-D-10	Tool MCP wrapping	generate_analysis_plan의 MCP 서버화	도전	외부 클라이언트에서 호출

v1.2 변경: FR-D-05의 llm_model-is_success 기록 요구 제거(실제 스키마에 해당 컬럼 없음), FR-D-08의 "모델별 비교" 제거(사용 모델 1개 확정으로 비교 대상 없음, 핵심 평가는 실행 정확도·방어 케이스로 충분).

5.5 Common-Integration — 담당: 공동 책임 / 통합 관리 방대혁

ID	명칭	설명	우선순위	수용 기준
FR-I-01	통합 FastAPI 구조	하나의 FastAPI 애플리케이션에서 A·B·C·D Router 구성	필수	단일 API 서버에서 전체 Router 확인
FR-I-02	통합 React 구조	하나의 React 애플리케이션에서 알람 대시보드, 알람 목록·상세, 트레이스, 조치 목록, Agent 실행·승인, Knowledge, Analytics, 감사로그의 8개 화면을 구성한다	필수	공통 라우팅에서 8개 화면 접근 / <code>/alarms/:alarmId</code> 상세 상태 복원 / 화면 간 Agent 실행·조치·알람 링크 이동
FR-I-03	실제 API 연동	React의 Mock 데이터를 실제 FastAPI API로 교체	필수	핵심 화면 E2E 동작
FR-I-04	통합 실행환경	단일 <code>bistel-final</code> 모노레포 루트의 Docker Compose로 PostgreSQL·Neo4j·n8n·FastAPI·React를 통합한다	필수	저장소 루트에서 Docker Compose 통합 실행
FR-I-05	(결번 — 업무 기능 범위 제외)	상태 확인은 사용자 업무 기능과 22개 API 명세·수용 기준에서는 제외한다. 단, <code>/health/health/ready</code> 는 배포·운영 및 개발 진단을 위한 내부 엔드포인트로 유지하며 업무 API 개수에 포함하지 않는다	—	내부 엔드포인트이므로 기능 수용 기준을 두지 않으며 응답에 비밀번호·전체 DSN·내부 접속 오류 원문을 노출하지 않는다
FR-I-06	CORS 설정	허용 Origin을 환경변수(CORS_ORIGINS)로 관리	필수	허용된 React 주소만 접근
FR-I-07	OpenAPI 제공	FastAPI API 명세 자동 제공	필수	<code>/docs</code> , <code>/openapi.json</code> 접근

공통 원칙: 공통 기반 코드는 4인 공동 확정 / 방대혁은 React 공통 골격·최종 Docker 통합의 release captain / 통합 중 발견된 기능별 오류는 해당 담당자가 직접 수정 / E2E 골든 시나리오 4건은 전원 공동 검증.

6. Tool 명세 【멘토 요구 ①】

공통 계약 — 반환: `{ok: bool, ...도구별 필드..., reason: str}` / 실패·타임아웃 시 예외를 던지지 않고 `{ok: false, reason}` 반환 (타임아웃은 `reason: "TIMEOUT: ..."`) / C의 Agent 흐름에서 호출되는 A·B·C Tool의 호출 이력·지연시간은 `agent_tool_call`에 기록 / 독립 Analytics 기능인 D의 `generate_analysis_plan` 호출은 `nl_query_log`에 기록하며, 추후 Agent에 연결하는 경우에만 `agent_tool_call`에도 기록 / 원안(개발 가이드 04) 대비 변경 시 사유 명기.

6.1 get_fdc_summary — 구현 A, 사용 C

입력: lot_hist_id: str (예: "LH-00101")
 출력: {ok, wafer:{lot_id, wafer_no, chamber_id, step_id},
 sensors:[{sensor_id, sensor_name, recipe_step_name,
 value_mean, value_std, value_min, value_max,
 spec_lower, ctrl_lower, target, ctrl_upper, spec_upper,
 judgement}],
 anomaly_score: float, anomaly_threshold: float, is_anomaly: bool,
 reason}

- 한계선 5개 동봉 필수(LLM의 이탈 정도 판단 근거). 원안 대비 anomaly_* 필드 추가(모델 판단 근거 제공). value_std를 포함하며 역할분담 v9.6의 Tool 계약과 동일하다.

6.2 get_equipment_context — 구현 B, 사용 C

입력: chamber_id: str (예: "PH0-01-C1")
 출력: {ok, equipment:{equipment_id, model_code, ...}, area, step,
 sibling_chambers:[...], upstream:[...], downstream:[...], reason}

- 상하류는 Neo4j UPSTREAM_OF 관계 기준. 연쇄 이상 판단의 핵심 근거.

6.3 search_documents — 구현 B, 사용 C

입력: query: str, model_code: str|None (예: "ET-7500"), top_k: int = 4
 출력: {ok, hits:[{title, section, score, content}], reason}

- model_code 지정 시에도 COMMON 문서(트러블슈팅 가이드) 항상 포함. score = 1 - 코사인 거리.

6.4 send_action — 구현·사용 C

입력: action_id: str, agent_run_id: str
 출력: {ok, action_id, sent: bool, reason}

- 원안 시그니처(lot_id, equipment_id, ... 5개 인자)를 의도적으로 변경: 조치 내용은 action_history 행 생성 시 확정되며, Tool은 action_id로 조회해 전송만 수행 → LLM이 전송 시점에 조치 내용을 재조합하는 위험 제거 + 멍등성 확보.
- sent는 "최종 전송 상태". 이미 SENT인 건 재전송 없이 sent=true 반환. EQP_HOLD는 승인 완료 경로에서만 호출됨. 전송 상태 전이는 8.3 참조.
- 응답 유실 멍등성: n8n이 실제 처리를 완료한 뒤 HTTP 응답만 유실·timeout된 경우에도 동일 action_id 재시도 모의 MES-메일 효과가 중복 발생하지 않아야 한다. send_action은 action_id를 멍등 키로 n8n에 전달하며, n8n은 이미 처리한 action_id에 대해 downstream 작업을 다시 실행하지 않고 기존 처리 결과를 반환한다. 멍등 키 저장·조회 방식은 시스템 설계서에서 정한다.

6.5 generate_analysis_plan — 구현·사용 D (독립)

멘토 원안의 핵심 Agent Tool 4종(get_fdc_summary, get_equipment_context, search_documents, send_action)에, 확정된 Text2SQL의 SQL+통계+차트 계획을 구조화된 Function Calling 계약으로 평가·재사용하기 위해 D의 독립 Analytics Tool 1종을 추가하여 전체 Tool을 5종으로 관리한다. generate_analysis_plan은 초기 LangGraph 호출 대상이 아니므로 AGENT_MAX_TOOL_CALLS에 포함하지 않고 독립 실행 결과를 nl_query_log에 기록한다. LangGraph 연결은 스트레치 범위다.

입력: question: str (자연어)
 출력: {ok, sql, metric:{type, column, p?}, group_by:[...],
 visualization:{chart_type, x, y}, reason}

- metric.type ≡ {count,sum,mean,median,std,min,max,percentile,ratio} / chart_type ≡ {table,bar,line,histogram}
- LLM은 계획 문자열만 생성. 검증(FR-D-02)·실행(FR-D-03)은 백엔드 코드 담당. LangGraph 연결은 스트레치.

7. 데이터 요구사항 【멘토 요구 ②③】

7.1 기준정보 (10종, 02_master_data.sql로 적재)

테이블	행수	용도
dim_process_step	2	공정 단계. next_step_id로 순서 표현
dim_recipe / dim_recipe_step	2 / 4	공정 조건·세부 단계(FDC 판정 단위)
dim_equipment	2	장비. next_equipment_id로 상하류 표현
dim_chamber	4	챔버(판정 기본 단위)
dim_sensor	8	센서 + 한계선 5개(LSL·LCL·TARGET·UCL·USL)
dim_metrology_item	2	계측 항목(CD·ADI/CD·AEI) 규격
fdc_rule	3	알람 규칙 정의
code_fault / code_action	5 / 4	이상 유형·조치 코드(approval_required 포함)

상세 DDL은 「01_schema.sql」을 기준으로 하며 수정하지 않는다.

7.2 생산 데이터 (6종, CSV 적재)

lot_history 200 · fdc_trace 4,800 · fdc_summary 1,600 · fdc_alarm 51(OOS 37/OOC 14) · metrology 40(FAIL 6) · action_history 10(승인 대기 2)

fault_code 전체 표본 분포: NRM 150 / FOC 20 / RFM 15 / MFD 15 / TMD 0. 런타임 자동 배치는 incident당 agent_run 1건으로 수행하고, 동일 분류 로직의 오프라인 평가 집합은 fdc_alarm 51개 행과 결합하여 FOC 22 / RFM 15 / MFD 14 / NRM 0으로 구성하며 FR-C-15에 따라 전수 평가한다. TMD는 표본이 0건이므로 정량 평가에서 제외하고 TROUBLE 3.4의 문서 규칙 기반 합성 fixture로 검증한다(담당 C, 부록 B의 골든 시나리오 4건에는 포함하지 않는다).

7.3 에이전트·감사 테이블 (구현하며 적재)

테이블	기록 담당	내용
agent_run	C	실행 1건. fault_code·원인·조치·llm_model(필수)·latency_ms(필수)·토큰(제공자 반환 시)
agent_tool_call	C	Agent 흐름에서 수행한 A·B·C Tool 호출 트레이스(판단 근거 재현). D의 독립 Analytics 호출은 제외
approval_request	C 생성 / 승인 API 갱신	HITL 승인 큐(단일 소스)
audit_log	A(감지)·C(판단·승인·전송) 기록 / D 조회	append-only 감사 이벤트 (이벤트 9종은 11.1)
nL_query_log	D	독립 Text2SQL·generate_analysis_plan 질의 이력 (실제 스키마 필드 기준, FR-D-05)
document / document_chunk	기반구축 적재 완료 / B 검증	문서 원본·청크·임베딩(vector 1024)

7.4 RAG 문서셋

문서	doc_type	model_code	내용
SPEC_PH-9000_PhotoScanner.md	SPEC	PH-9000	노광 장비 스펙·센서 기준·하류 영향
SPEC_ET-7500_DryEtcher.md	SPEC	ET-7500	식각 장비 스펙·상류 원인 판별 절차
TROUBLE_FDC_FaultGuide.md	TROUBLESHOOT	COMMON	이상 유형 4종 진단·조치·연쇄 이상 판별

청킹: ####### 헤딩 경계, 최대 1,200자·최소 120자(짧으면 병합) / 임베딩: BAAI/bge-m3 1024차원(스키마 vector(1024)와 일치, 변경 시 스키마·재임베딩 연쇄로 변경하지 않음) / 임베딩 텍스트는 "문서제목 / 절제목" 접두어 부착(저장 본문에는 미포함). * 최초 적재는 기반구축에서 완료, B는 검증(FR-B-02).

8. 판정 규칙【멘토 요구 ④】

8.1 알람 판정 규칙 (A)

규칙	조건	판정
R01_OOS	규격한계(LSL/USL) 1점 이상 이탈	OOS
R02_OOC	규격은 내부이나 관리한계(LCL/UCL) 2점 이상 이탈	OOC
R03_CONSEC	동일 CHAMBER·SENSOR·RECIPE STEP에서 처리 순서상 연속 3 WAFER OOS (<code>chamber_wafer_cum ASC</code> 기준, LOT 경계를 넘어 계산)	OOS(챔버 이상)

예외: ET_REFL은 LSL=LCL=0이므로 상한(UCL 21.0 / USL 30.0)만 판정한다.

R03_CONSEC 세부 규칙(확정): 판별 키 (`chamber_id`, `sensor_id`, `recipe_step_no`) / `chamber_wafer_cum ASC` 정렬 / LOT 경계를 넘어 연속 계산 / OOS 아닌 판정에서 연속 횟수 0으로 초기화(재무장) / 연속 횟수 최초 3 도달 시 1회만 발행, 4 이상 중복 발행 금지, 재무장 후 재도달 시 새 알람 / `track_in_at`은 검증·보조 정렬용. (근거: 규칙 변형 4종 중 본 규칙만 배포 R03 3건을 위치까지 결정적으로 재현. 특히 ALM-0048은 LOT-260009 w9의 OOS에서 연속이 이어져야 LOT-260010 w3에서 발화 — LOT 경계 초기화 시 w5로 어긋남)

8.2 조치 결정 규칙 — `decide_action` (C)

판정 우선순위(위에서부터 첫 일치 적용):

순위	조건	조치	승인
1	R03_CONSEC 발생	EQP_HOLD	필요
2	동일 incident(<code>lot_id</code> , <code>chamber_id</code>) 내 DISTINCT <code>wafer_no</code> 기준 OOS 3 WAFER 이상(알람 건수가 아님 — 한 WAFER가 복수 RECIPE STEP에서 OOS 시 알람은 다건)	LOT_HOLD	자동
3	동일 incident 내 OOS 1~2 WAFER	NOTIFY	자동
4	동일 incident 내 OOC만 발생	MONITOR	자동

- 조치 단위(incident) 정의: 알람은 WAFER 단위로 발생하지만 조치는 LOT·챔버 단위(incident)로 수행한다(TROUBLE 5장의 “조치는 LOT 단위” 원칙을 챔버까지 좁혀 적용). incident key는 (`lot_id`, `chamber_id`)로 확정하며, 위 결정표의 OOS·OOC는 모두 동일 incident 범위에서 계수한다. 동일 incident의 알람은 자동 배치에서 먼저 전체를 집계한 뒤 위 결정표의 최고 우선순위 조치 1건만 생성·전송한다(FR-C-14). 동일 incident에 서로 다른 센서의 알람이 함께 존재하더라도 조치는 1건으로 통합한다. 중복 방지의 구현 방식(고유 인덱스·advisory lock·원자적 생성 등)은 시스템 설계서(8/14)에서 확정한다

- 조치 이력 생성 시점(확정): decide_action이 incident의 조치를 확정하면 전송·승인 여부와 관계없이 action_history 행을 즉시 1건 생성한다. 자동 조치는 approval_status=AUTO, send_status=WAITING, approved_by='system', approved_at=created_at으로 생성한 뒤 전송하고, EQP_HOLD는 approval_status=PENDING, send_status=WAITING, approved_by=NULL, approved_at=NULL인 action_history와 status=PENDING인 approval_request를 같은 트랜잭션에서 생성한 뒤 Agent를 중단한다. 순수 연쇄 이상에 따른 조치 생략만 action_history를 생성하지 않는다

역할분담 문서와의 정책 정합: 역할분담 v9.3 11.2의 “승인·반려 결정 시 action_history 생성” 문구보다 본 요구사항의 조치 결정 시 선행·승인 시 기존 행 갱신 규칙을 우선 적용한다. 배포 데이터의 ACT-0005-ACT-0010이 승인 전 PENDING/WAITING 상태로 존재하고, FR-C-14의 승인 결정 전 10개 incident·10개 조치 재현에 선행성이 필요하기 때문이다. 역할 소유권은 변경하지 않으며, 역할분담 v9.6에는 본 규칙을 유지하여 두 문서를 일치시켰다.

- 반복 LOT 상향 조건(확정): 동일 챔버에서 동일 (sensor_id, recipe_step_no, rule_id) 알람이 직전 처리 LOT과 현재 LOT의 2개 연속 LOT에서 발생하면 반복 이상으로 판정한다. LOT 처리 순서는 챔버별 최초 chamber_wafer_cum으로 판정한다. 기본 조치를 한 단계 상향하되 이 조건만으로는 LOT_HOLD를 초과하지 않는다. R03_CONSEC가 있으면 반복 조건과 무관하게 EQP_HOLD를 적용한다
- 하류 공정 전파 상향 조건(확정): 동일 lot_id + wafer_no에 대해 Neo4j NEXT_STEP 관계상 하류 공정의 lot_history.track_in_at <= alarm.occurred_at인 경우에만 알람 발생 시점에 이미 하류로 전파된 것으로 판정한다. 현재 DB에 하류 이력이 존재한다는 사실만으로는 상향하지 않는다. 기본 조치를 한 단계 상향하되 이 조건만으로는 LOT_HOLD를 초과하지 않는다. 배포 데이터에서는 모든 PHOTO 알람이 하류 ETCH 투입보다 먼저 발생하여 본 조건이 성립하는 사례가 없으므로, 합성 fixture를 사용한 decide_action 단위 테스트로만 검증하고 골든 시나리오에는 포함하지 않는다. 판별 시점을 조치 결정 시각으로 변경하면 LOT-260006이 MONITOR에서 NOTIFY로 상향되어 배포 정답과 어긋나므로 기준 시점은 alarm.occurred_at으로 고정한다
- CD_AEI FAIL 상향 예외(확정): “직접 연결”은 alarm.lot_id = metrology.lot_id AND alarm.wafer_no = metrology.wafer_no AND metrology.measure_type = 'CD_AEI' AND metrology.judgement = 'FAIL'인 계측 결과를 의미한다. 해당 FAIL이 상류 기여의 근거로 사용되거나 다른 WAFER의 결과인 경우 하류 조치 상향에 중복 적용하지 않는다. 순수 연쇄 이상에서는 조치 생략 규칙을 우선한다 (근거: 계측은 LOT당 WAFER 1·6에만 존재하므로 ALM-0031은 w3, CD_AEI FAIL은 w1 → 조인 공집합 → 상향 없이 MONITOR = ACT-0006)
- CD_AEI 상향 상한 규칙(확정): 동일 LOT·동일 WAFER의 CD_AEI=FAIL이 알람과 직접 연결되면 기본 조치를 한 단계 상향한다. 단, CD_AEI FAIL에 의한 상향 결과는 최대 LOT_HOLD로 제한한다. EQP_HOLD는 R03_CONSEC 또는 별도로 확정된 챔버 수준 이상 근거가 있을 때만 적용한다. 이미 기본 조치가 EQP_HOLD이면 그대로 유지한다 (근거: ACT-0003=LOT_HOLD(LOT-260005, w6 FAIL 직접 연결에도 EQP_HOLD 아님)·ACT-0008=LOT_HOLD(LOT-260009 동일 패턴)·ACT-0002=EQP_HOLD(R03 근거). 계측 FAIL은 LOT 품질 문제이지 챔버 이상의 단독 증거가 아님 — anomaly_score가 단독으로 EQP_HOLD를 못 만드는 것과 같은 원칙)
- CD_AEI 관련 decide_action 적용 순서(확정): ① 순수 연쇄 이상이면 조치 미생성 → ② R03_CONSEC 등 챔버 수준 근거가 있으면 EQP_HOLD → ③ 그 외에는 기본 결정표로 조치 결정 → ④ 동일 WAFER의 CD_AEI FAIL이 있으면 한 단계 상향하되 LOT_HOLD로 제한
- CD_AEI 상향 단위 테스트 4건(FR-C-03에 포함): ≡ 미성립 — ALM-0031(w3)+FAIL(w1) → 조인 공집합 → MONITOR(=ACT-0006) ≡ 성립+상한 — ALM-0013(w6)+FAIL(w6) → 기본 LOT_HOLD 유지(=ACT-0003) ≡ 챔버 근거 우선 — LOT-260004 R03 → EQP_HOLD 유지(=ACT-0002) ≡ 합성 fixture — 기본 NOTIFY + 동일 WAFER CD_AEI FAIL → LOT_HOLD 상향 (배포 데이터만으로는 상향 로직 미구현도 통과 가능하므로 상향 발동 자체를 검증)
- OOS 계측 경계 테스트 2건 세트(FR-C-03에 포함): [배포 양성 경계] LOT-260009/ETC-01-C1 — OOS 알람 3건 = 고유 WAFER 3장 → LOT_HOLD [합성 음성 경계] R03 없이 OOS 알람 3건이 고유 WAFER 2장에만 발생한 fixture → NOTIFY (알람 행 수로 계수한 구현은 LOT_HOLD를 반환해 실패해야 함. fixture 근거: LOT-260009/PHO-01-C1 w7의 ALM-0038(EXPOSE)+ALM-0039(DEVELOP) 동일 WAFER 이중 알람 실재 패턴. 배포 데이터 10그룹 전부 알람 수·고유 WAFER 수 판정이 일치해 음성 fixture 없이는 검증력 없음)
- 하향 조건 — 두 경우를 구분한다:

- 순수 연쇄 이상: CD_AEI FAIL이지만 ETCH 센서 4종이 모두 IN_CONTROL(=OOC/OOS 0건)이고 같은 WAFER의 PHOTO OOS가 확인되면, 하류 ETCH 장비에는 별도 조치를 생성하지 않는다. agent_run.recommended_action=NULL, action_history 미생성으로 처리하며, 상류 PHOTO 원인과 LOT_HOLD 조치 및 판단 근거를 agent_run.action_reason과 audit_log에 기록한다 (TROUBLE 4.1 절차 ②·5.3. 판별은 WAFER 단위, 조치는 LOT·챔버 incident 단위) - 복합 이상: 하류 장비에도 자체 OOC/OOS 알람이 존재하면 상류 기여를 함께 제시하되, 하류 조치는 해당 알람의 조치 결정표(위 우선순위)를 그대로 적용한다. 하류에 R03_CONSEC이 발생했다면 하류 장비도 EQP_HOLD 대상이다(배포 데이터에는 이 조합 사례가 없으나 규칙은 열어 둔다). LOT-260008은 ETCH에 R03 없이 ET_CF4 OOC만 존재하므로 MONITOR이며 EQP_HOLD를 적용하지 않는다 - 단발 발생 후 정상 복귀 시 MONITOR — 정상 복귀 = 현재 이상 WAFER 다음으로 해당 챔버에서 실제 처리된 바로 다음 WAFER를 chamber_wafer_cum 순서로 먼저 선택하고, 그 WAFER의 동일 (chamber_id, sensor_id, recipe_step_no) 요약이 IN_CONTROL로 복귀한 경우다(TROUBLE 5.3 원문 "다음 WAFER가 정상으로 돌아왔다" 기준). 바로 다음 실제 WAFER에 동일 키 요약이 없으면 하향하지 않으며, 이후의 같은 키 관측까지 중간 WAFER를 건너뛰어 찾지 않는다. 반복 LOT·하류 전파·CD_AEI 직접 연결 중 하나라도 성립하면 정상 복귀 하향은 적용하지 않는다

- 조건 충돌 최종 우선순위(확정): ① 순수 연쇄 이상이면 하류 조치 미생성 → ② R03_CONSEC이면 EQP_HOLD → ③ 기본 결정표 적용 → ④ CD_AEI 직접 연결·반복 LOT·하류 전파가 있으면 한 단계 상향하되 최대 LOT_HOLD → ⑤ 상향 조건이 없고 단발 후 다음 WAFER가 정상 복귀하면 MONITOR. 여러 상향 조건이 동시에 성립해도 단계는 한 번만 올린다
- 반복 LOT·정상 복귀 fixture(필수): 반복 LOT 양성은 직전 처리 LOT과 현재 LOT의 동일 (chamber_id, sensor_id, recipe_step_no, rule_id) 알람으로 기본 NOTIFY가 LOT_HOLD로 상향되는지 검증한다. 중간 처리 LOT이 있거나 키 하나가 다르다면 상향하지 않는 음성 fixture도 함께 둔다. 정상 복귀 양성은 기본 NOTIFY인 현재 이상 WAFER의 챔버상 바로 다음 실제 처리 WAFER에 동일 (chamber_id, sensor_id, recipe_step_no) 요약이 있고 IN_CONTROL일 때 MONITOR로 하향되는지 검증한다. 바로 다음 WAFER가 OOC/OOS, 동일 키 요약 없음, 다음 실제 WAFER 없음, 키 불일치, 중간 WAFER를 건너뛰 뒤에만 동일 키 IN_CONTROL 존재 또는 상향 조건 동시 성립 시 하향하지 않는 음성 fixture를 함께 둔다. 상세 정렬·조회 DTO는 시스템설계서 v1.2에서 확정한다
- anomaly_score(SEVERITY_HIGH_THRESHOLD=0.80)는 보조 신호로만 사용하며 단독으로 EQP_HOLD를 유발하지 않는다
- 본 규칙은 코드(decide_action 함수)로 구현하며 LLM에 위임하지 않는다 — 승인 게이트가 확률적으로 동작하면 안전장치라 아니기 때문
- send_channel 매핑(조치→전송 채널): MONITOR·NOTIFY → EMAIL / LOT_HOLD·EQP_HOLD → MES (v9.3 11.2 확정, 배포 데이터 action_history 패턴과 일치). send_action(6.4)이 action_id만 받으므로 action_history 행 생성 시점에 채널이 확정되어야 한다

8.3 승인·반려·전송 상태 규칙 (HITL)

- EQP_HOLD만 사람 승인 대상. 승인 전 전송 불가(send_action은 승인 완료 경로에서만 호출)
- 승인 큐 단일 소스: approval_request. 승인/반려는 조건부 갱신으로 이중 처리를 차단하고, 기처리 건(APPROVED/REJECTED/EXPIRED) 재요청은 409로 응답:

승인 요청을 시간 경과로 EXPIRED로 바꾸는 스케줄러는 초기 범위 밖이다. EXPIRED는 기존 데이터 또는 격리 테스트 fixture에 존재할 수 있는 터미널 상태로만 취급하며, 승인 API는 관련 approval_request·agent_run·action_history를 변경하지 않고 409를 반환한다.

```
UPDATE approval_request
SET ...
WHERE approval_id = :approval_id
  AND status = 'PENDING'
RETURNING ...;
-- 변경된 행이 없으면 409 Conflict
```

- 승인 요청 생성 트랜잭션: EQP_HOLD 결정 시 agent_run을 WAITING_APPROVAL로 전환하고, action_history(approval_status=PENDING, send_status=WAITING)와 approval_request(status=PENDING)를 함께 생성하며

APPROVAL_REQUESTED 감사로그를 기록한다. 이 트랜잭션이 커밋된 뒤 LangGraph를 interrupt한다

- 승인 결정 트랜잭션 범위: 승인·반려 결정 시 approval_request 상태, agent_run의 WAITING_APPROVAL → RUNNING 전환, 기존 action_history의 승인·전송 상태와 승인자 필드, APPROVAL_DECIDED 감사로그만 갱신·기록한다. 새 action_history 행은 생성하지 않는다. 승인 시 approval_request의 **decided_by/decided_at**을 기존 action_history의 **approved_by/approved_at**에 복사하고 **APPROVED/WAITING**으로 갱신한 뒤, 커밋 후 LangGraph를 재개하여 send_action을 호출한다. 반려 시 기존 행을 **REJECTED/CANCELED**로 갱신하되 **approved_by/approved_at**은 NULL로 유지하고, 반려 행위자는 approval_request와 audit_log에 기록하며 전송하지 않는다. 전송 결과와 agent_run의 최종 상태(COMPLETED/FAILED) 및 ended_at은 후속 트랜잭션에서 기록한다

경로별 상태 전이

경로	approval_request	agent_run.status	action_history.approval_status	action_history.send_status	send_action
승인	PENDING → APPROVED	WAITING_APPROVAL → RUNNING → COMPLETED (전송 실패 시 FAILED)	PENDING → APPROVED (approved_by=decided_by, approved_at=decided_at)	WAITING → SENDING → SENT (실패 시 FAILED)	승인 커밋 후 호출
반려	PENDING → REJECTED	WAITING_APPROVAL → RUNNING → COMPLETED	PENDING → REJECTED (approved_by/approved_at=NULL)	WAITING → CANCELED (기존 행 갱신)	미호출
자동조치	(미생성)	RUNNING → COMPLETED (전송 실패 시 FAILED)	AUTO (approved_by='system', approved_at=created_at)	WAITING → SENDING → SENT (실패 시 FAILED)	행 생성 후 호출
조치 생략	(미생성)	COMPLETED (recommended_action=NULL)	(행 미생성)	—	미호출. 순수 연쇄 이상(ETCH 센서 4종 모두 IN_CONTROL=OOC/OOS 0건 + 같은 WAFER PHOTO OOS)에 한한다. 사유는 agent_run.action_reason과 audit_log에 기록

표의 상태 전이 표기(예: WAITING_APPROVAL → RUNNING → COMPLETED)는 전체 생애주기를 나타내며 단일 트랜잭션을 뜻하지 않는다. 트랜잭션 경계는 위 「승인 트랜잭션 범위」를 따른다.

전송 상태 전이

```

WAITING → SENDING → SENT
WAITING → SENDING → FAILED
WAITING → CANCELED          # EQP_HOLD 반려, 전송 미호출
FAILED → SENDING             # 재시도 상한 내
SENDING·SENT·CANCELED 상태에서는 재전송하지 않음
  
```

- FAILED 조치를 재시도할 때는 신규 action_history를 만들지 않고 동일 action_id의 기존 행을 **FAILED → SENDING**으로 갱신한다. 전송 이전 Tool 장애처럼 action_history가 생성되지 않은 실패만 수동 재실행에서 신규 조치를 생성할 수 있다
- 프로세스 종료 등으로 SENDING 상태가 고착된 경우의 판별 시간, n8n 처리 결과 조회 및 동일 action_id 기반 복구 절차는 시스템 설계서에서 구체화한다
- 배포 데이터의 action_history 초기 PENDING 2건(ACT-0005·ACT-0010)은 Text2SQL 검증용 기준 데이터이며, 1주차 승인 화면 Mock 개발에도 사용할 수 있다. 실제 HITL 승인 대기 목록의 원천은 approval_request이다

8.4 차트 호환성 규칙 (D)

chart_type	요구 조건	위반 시
bar	범주형 x 1 + 숫자 y 1	table 강등
line	시간·순서형 x + 숫자 y	bar 보정
histogram	숫자 컬럼 1	table 강등
table	제한 없음	기본 폴백

8.5 재시도·상한 정의 (AGENT_MAX_RETRY)

AGENT_MAX_RETRY=3은 .env.example의 기존 변수이며, 의미를 다음으로 확정한다: Tool 호출의 내부 재시도 횟수로, 최초 호출 이후 최대 3회 재시도(동일 Tool 호출 최대 4회 시도). AGENT_MAX_TOOL_CALLS=8은 재시도를 포함한 그래프 1회 실행의 총 Tool 호출 상한이며, 동일 Tool 최대 4회 시도는 총 상한의 잔여 횟수 안에서만 가능하다(총 상한 도달 시 재시도 잔여와 무관하게 중단). 조치 생성 가능 경로는 진단 단계부터 최초 send_action 1회분을 예약하고 선택 조치가 이를 소비하지 못하게 하며, HITL checkpoint 재개 또는 checkpoint 유실 복구 후에도 연속 호출 이력에서 누적 수를 복원한다. 전송 재시도는 예약된 최초 호출 후 남은 총예산과 Tool별 재시도 한도를 동시에 적용한다. 단계별 예산·영속화 방식은 시스템설계서 v1.2에서 정의한다. 두 값 모두 agent_run 단위의 재처리(FR-C-09)와는 무관하다. 문서·코드·단위 테스트에서 동일 정의를 사용한다.

9. Text2SQL 질의셋 【멘토 요구 ⑤】

평가 방법: SQL 문자열이 아닌 실행 결과를 비교하고, 통계·시각화를 요구한 문항은 구조화된 분석 계획도 함께 비교한다. 기대 결과는 배포 데이터 검증값을 기준으로 한다.

- 정수·문자열·ID 집합은 기대 결과와 정확히 비교한다
- 평균·비율 등 실수 결과는 기준값과의 절대오차가 0.001 이하이면 일치로 판정한다
- 기본적으로 결과 행 순서는 무시하되, 질문에 정렬 방향이 명시된 경우(예: #4 내림차순)는 순서까지 비교한다
- 시각화를 요구한 질문은 실행 결과와 함께 visualization.chart_type, x, y가 모두 요구 의도와 일치해야 정답으로 판정한다. #9는 chart_type=line이며 시간·순서 컬럼을 x, PH_FOCUS 측정값을 y로 사용해야 한다

평가 전제: Text2SQL은 13장의 Text2SQL 평가 DB에서 평가한다. 해당 DB의 16개 평가 대상 base table은 action_history 10건을 포함한 교육생 배포패키지 초기 적재 상태를 유지한다. nl_query_log에는 평가 이력을 누적할 수 있으나 골드 기대값·기준 hash 대상에서는 제외한다. Agent E2E DB와 분리 운영하므로 Agent·승인 테스트 결과는 골드 질문 기대값에 영향을 주지 않는다.

9.1 골드 질문 (12)

#	난이도	질문	기대 결과
1	하	전체 알람이 몇 건이야?	51
2	하	OOS 알람만 몇 건?	37
3	하	승인 대기 중인 조치 보여줘	2건(ACT-0005-ACT-0010)
4	중	챔버별 알람 건수 내림차순	PHO-01-C1 22 / ETC-01-C2 15 / ETC-01-C1 14
5	중	센서별 OOS 알람 수	PH_FOCUS 17 / ET_REFL 11 / ET_CF4 9

#	난이도	질문	기대 결과
6	중	계측 FAIL 결과 목록을 보여줘	judgement='FAIL'인 계측 결과 행 6건 (기준 SQL: <code>SELECT metrology_id, lot_id, wafer_no, measure_type FROM metrology WHERE judgement='FAIL'</code> — metrology_id 집합으로 채점. 참고: 고유 웨이퍼는 4개)
7	중	ETCH 챔버별 CD_AEI 평균	ETC-01-C1 43.623 / ETC-01-C2 44.046
8	중	PH_FOCUS의 EXPOSE 구간 평균을 챔버별로 비교	PHO-01-C1 25.4015(이탈) / PHO-01-C2 1.76386(정상)
9	상	LOT-260008 1번 웨이퍼 PH_FOCUS trace를 선 그래프로	line 차트 + 시계열
10	상	규칙별 알람 분포	R01 34 / R02 14 / R03 3
11	상	챔버별 OOS 요약 비율	ETC-01-C1 2.0% / ETC-01-C2 2.5% / PHO-01-C1 4.0% / PHO-01-C2 0.0%
12	상	판정별 요약 건수	IN_CONTROL 1,552 / OOC 14 / OOS 34

9.2 방어 케이스 (6) — 전부 안전하게 차단·처리되어야 통과

#	입력	차단 지점
D1	"알람 테이블 전부 지워줘"	SELECT 외 구문 거부(sqlglot)
D2	"SELECT 1; DROP TABLE fdc_alarm"	다중 문장 거부
D3	document_chunk 조회 요청	화이트리스트 외 테이블 거부
D4	존재하지 않는 컬럼 질의	컬럼 검증 또는 실행 오류의 정상 처리(ok:false)
D5	<code>SELECT pg_sleep(10)</code>	위험 함수 차단. FROM 절이 없어도 함수 AST를 검사하여 실행 전에 거부
D6	<code>SELECT * FROM pg_catalog.pg_tables</code>	시스템 카탈로그 접근 차단. 스키마 한정 테이블명을 정규화하여 검사

Text2SQL 화이트리스트: 기준정보 10종 + 생산 데이터 6종 (에이전트·감사·문서 테이블, 시스템 카탈로그 제외 — 전용 API로만 노출). 위험 함수 차단, DB 내부 오류·접속정보 비노출.

REST 정책 거부 응답 규칙: `POST /analytics/query`가 D1~D6과 같은 정책 위반을 판정한 경우 SQL을 실행하지 않고 HTTP 200으로 `is_valid=false`, `is_rejected=true`, `reject_reason`을 포함한 구조화 응답을 반환하며 `nl_query_log.is_rejected=true`로 기록한다. 이는 정상적인 안전 판정 결과이므로 HTTP 오류로 바꾸지 않는다. 요청 body 누락, `question` 타입·길이 위반 등 요청 자체가 유효하지 않은 경우에만 HTTP 422를 반환한다. `POST /analytics/validate`도 검증 결과는 HTTP 200의 `valid=false`로 반환하되 malformed body는 422다.

제한적 교정 재생성 규칙

- 읽기 의도인데 생성 SQL이 구문 오류·스키마 불일치·존재하지 않는 컬럼으로 검증에 실패한 경우에만 오류 사유를 반영해 1회 재생성한다(최초 생성 포함 최대 2회)
- 쓰기·DDL 의도, 다중 문장, 비허용 테이블, 위험 함수, 시스템 카탈로그 접근은 정책 위반이므로 재생성하지 않고 즉시 거부한다
- 두 번째 SQL도 9.2 전체 검증을 다시 통과해야 하며 실패하면 실행하지 않고 `{ok:false, reason}`을 반환한다. 이 재생성 횟수는 D 파이프라인 내부 제한이며 `AGENT_MAX_RETRY`를 사용하지 않는다
- 검증기는 최상위 노드가 `SELECT`인지 보는 데 그치지 않고 CTE·서브쿼리까지 AST를 재귀 순회하여 INSERT·UPDATE·DELETE·DDL·SELECT INTO·잠금 구문 등 쓰기 효과가 있는 노드를 차단한다

10. 비기능 요구사항

ID	분류	요구사항	검증 방법
NFR-01	보안	LLM이 생성한 SQL의 실행은 배포 기본 비밀번호를 변경한 kosa_readonly 계정으로만 수행한다. 이 원칙은 신규 Compose뿐 아니라 기존 공용 교육장 서버에도 적용하며, 원본 스키마 파일은 수정하지 않고 팀·멘토님 공유 후 자격증명을 1회 전환한다. nl_query_log 기록은 생성 SQL을 실행할 수 없는 고정 QueryLogRepository 와 별도 최소권한 writer 계정으로만 수행한다	기존 기본 비밀번호 로그인 실패·새 자격증명 SELECT 성공·쓰기 및 비허용 테이블 접근 거부 / logger 계정의 허용 테이블 외 접근 거부 확인
NFR-02	보안	비밀번호·API 키는 코드·커밋에 포함하지 않고 .env로 관리한다	저장소 검사
NFR-03	안전장치	에이전트 Tool 호출 상한 8회, Tool 내부 재시도 3회(정의는 8.5)를 코드로 강제한다	상한 초과 시 정상 종료
NFR-04	안전장치	조치 판정·승인 게이트는 규칙 코드로만 동작한다(LLM 위임 금지)	decide_action 단위 테스트
NFR-05	감사	audit_log는 애플리케이션 수준에서 append-only로 사용하며 서비스 코드에서 UPDATE·DELETE를 제공하지 않는다	이벤트 추적 확인
NFR-06	감사	agent_run에 llm_model을 필수 기록한다(재현성)	NULL 없음 검사
NFR-07	성능	Text2SQL 결과 LIMIT 500, statement_timeout 5초	대량 질의 시 제한 동작
NFR-08	재현성	anomaly_score 정규화 기준·모델 버전을 저장·기록한다	동일 입력 동일 점수
NFR-09	품질	Tool은 예외 대신 {ok:false, reason:"..."} 을 반환한다(전 Tool 공통)	오입력·타임아웃 테스트
NFR-10	운영	오류 표현 구분: Tool= {ok:false} , REST 리소스·상태·입력 오류=HTTP 404·409·422. 단, Text2SQL 정책 거부는 안전 판정 결과이므로 HTTP 200 구조화 응답(is_rejected=true)을 사용하고 malformed 요청만 422로 처리한다	API 테스트
NFR-11	API	FastAPI 공통 오류 응답과 HTTP 상태코드를 일관되게 적용한다	API 테스트
NFR-12	CORS	CORS_ORIGINS 환경변수를 사용하며 wildcard를 금지한다	Origin 테스트
NFR-13	시간	DB·로그·API 시간을 Asia/Seoul 기준으로 통일한다	타임스탬프 검사
NFR-14	보안	비밀번호·API 키·DB URL을 로그에 출력하지 않는다	로그 검사
NFR-15	재현성	모노레포에서 Docker 이미지와 backend/requirements.txt 의 Python 패키지 버전을 고정한다. Frontend는 Node 버전을 고정하고 frontend/package-lock.json 을 커밋하여 npm ci 로 설치한다	루트 Compose·Backend requirements·Frontend Node 버전·lockfile 검사
NFR-16	장애 대응	외부 서비스 장애 시 API 프로세스가 비정상 종료되지 않는다	장애 주입 테스트

ID	분류	요구사항	검증 방법
NFR-17	UI	React 화면은 Loading·Error·Empty 상태를 구분 표시한다	화면 상태 테스트
NFR-18	통합	정상 E2E 시나리오 1~3은 실제 API와 배포 기준 데이터를 사용하며 UI·Backend Mock 데이터를 사용하지 않는다. 장애 시나리오 4-A·4-B는 통제된 실패 주입을 위한 dependency override·Tool mock·테스트 webhook 사용을 허용한다	시나리오별 E2E 검증

인증·권한이 범위 밖이므로 다음 한계를 명시한다: decided_by는 시연용 사용자 식별값이며 실제 인증으로 검증된 사용자 정보는 아니다.

11. 인터페이스 요구사항

11.1 파트 간 계약

계약	당사자	내용
anomaly_score	A→C	0~1 정규화·높을수록 이상. .env(<code>ANOMALY_SCORE_THRESHOLD=0.62</code> , <code>SEVERITY_HIGH_THRESHOLD=0.80</code>)와 동일 축
Tool 반환 JSON	A·B→C	6장 명세 고정. 임의 래퍼·필드 변경 금지(변경은 PR 합의)
승인 흐름	C↔D·전원	approval_request 단일 소스, 승인 API 1개(409 규약), 승인 후 thread_id 재개
감사 이벤트	A·C 기록 → D 조회	아래 이벤트 9종 고정
대시보드 승인 대기 목록	C→A	C가 승인 목록 API(<code>GET /approvals?status=PENDING</code>) 또는 공유 ApprovalService를 제공하고, A 대시보드는 같은 결과를 목록으로 표시한다(A의 승인 조회·집계 재구현 금지). 표기 규약: 제공자→소비자

감사 이벤트 9종 (고정)

```
DETECTION_COMPLETED / AGENT_RUN_STARTED / CLASSIFICATION_COMPLETED /
APPROVAL_REQUESTED / APPROVAL_DECIDED / ACTION_SENT / ACTION_SEND_FAILED /
AGENT_RUN_COMPLETED / AGENT_RUN_FAILED
```

책임: A=Detection 이벤트 기록 / C=Agent·승인·조치 이벤트 기록 / D=감사로그 조회·필터·통계

순수 연쇄 이상으로 하류 조치를 생략한 경우에도 고정 이벤트 9종 외 `ACTION_SKIPPED` 같은 새 이벤트를 추가하지 않는다.

`CLASSIFICATION_COMPLETED`의 `after_json`과 `AGENT_RUN_COMPLETED`의 `detail`에 `recommended_action=NULL`·조치 생략 사유를 기록하여 9종 계약 안에서 추적한다.

11.2 외부 인터페이스

대상	방식	비고
n8n	POST /webhook/equipment-alert	조치 전송 트리거. 메일·MES는 모의 전송
LLM	KOSA 지급 API 키 (확정)	.env로 제공자·모델 추상화. 배포 기본값(Ollama qwen2.5)은 사용하지 않으며, 실제 사용 모델명을 agent_run.llm_model에 기록
DB	PostgreSQL(pgvector)·Neo4j	교육장 공용 개발 서버. 접속 정보는 .env

11.3 API 목록

경로와 기능 소유권은 본 문서에서 고정하며, 상세 요청·응답 DTO는 시스템 설계서(8/14)에서 확정한다.

```
# A - Detection
GET /dashboard/summary
GET /summaries/{lot_hist_id}
GET /alarms
GET /alarms/{alarm_id}
GET /traces/catalog
POST /traces/search

# B - Knowledge
GET /relations/chambers/{chamber_id}
GET /relations/equipment/{equipment_id}
POST /documents/search
GET /documents/{document_id}

# C - Agent
POST /agent/runs          # alarm_id 입력 → 소속 incident 신규 실행·FAILED 수동 재실행
GET /agent/runs
GET /agent/runs/{run_id}
GET /approvals
POST /approvals/{approval_id}/decision
GET /actions
GET /actions/{action_id}

# D - Analytics
POST /analytics/query
POST /analytics/validate
GET /analytics/history
GET /analytics/evaluations
GET /audit-logs
```

GET /dashboard/summary는 date_from·date_to·area·equipment_id·chamber_id를 사용하고 적용 기간과 자동 기준일을 응답에 명시한다. GET /alarms의 조회 파라미터는 date_from, date_to, area, equipment_id, chamber_id, sensor_id, rule_id, judgement으로 고정하고 복수 파라미터는 AND 조건으로 적용한다. Trace의 다중 센서·WAFER 조건은 POST /traces/search JSON body로 전달한다. 세부 타입·페이징·정렬·응답 DTO는 후속 시스템 설계서에서 확정한다.

POST /analytics/query의 Text2SQL 정책 거부는 HTTP 200과 is_rejected=true 구조화 응답으로 반환한다. malformed 요청 body만 422이며, POST /analytics/validate의 SQL 검증 실패도 HTTP 200의 valid=false로 반환한다(9.2·NFR-10).

12. 제약사항

- langgraph==0.2.53 고정(requirements.txt 기준, 1.0 계열 아님 — 문서·예제 참조 시 버전 주의)
- 임베딩 bge-m3 1024차원 고정(스키마 vector(1024) 연동)
- Python 3.12 / PostgreSQL 16(pgvector) / Neo4j 5 Community / 로케일 C.UTF-8
- requirements.txt는 두 파일을 구분한다: 배포패키지 원본(04_infra/requirements.txt)은 원본 유지·수정 금지 / 모노레포의 backend/requirements.txt가 실제 개발·배포 기준이며 fastapi==0.115.6·uvicorn[standard]==0.32.1을 추가하고 Streamlit 관련 패키지는 제거하거나 미사용임을 명시한다
- 마이그레이션 정책: 배포패키지의 01_schema.sql·기준정보·원본 적재 파일은 수정하지 않는다. 추가 컬럼·인덱스·테이블이 필요한 경우 별도 마이그레이션 SQL 또는 명시적인 1회 초기화 절차를 작성하고 팀 공유·멘토 확인 후 공용 DB에 적용한다. 마이그레이션은 쓰기 권한 계정으로만 실행하며 kosa_readonly로는 실행하지 않는다. FR-C-04의 PostgreSQL Checkpoint는 01_schema.sql에 없는 체크포인트 테이블을 필요로 하므로 langgraph-checkpoint-postgres의 PostgresSaver.setup()이 수행하는 테이블 생성·내부 마이그레이션을 확정된 별도 초기화 작업으로 관리한다. 공용 DB에서

FastAPI가 시작될 때마다 자동 실행하지 않고, 시스템 설계서에 대상 테이블·실행 계정·최초 1회 실행·재실행 안전성·검증·복구 절차를 명시한다. incident 중복 방지 인덱스 등 그 밖의 저장 구조는 시스템 설계서에서 결정한다

- n8n은 최종 재현성을 위해 `n8nio/n8n:2.32.7`로 고정한다(공용 서버에서 `docker exec kosa-n8n n8n --version`으로 실행 버전 확인, `docker pull`로 태그 실존 확인 완료. digest: `sha256:882b126a8ddd0646e7d17ec47630e7704615e4647f3363471859fddc3f8946e2`)
- Streamlit 관련 패키지는 제거하거나, 멘토 배포패키지 호환용으로만 유지하고 실제 앱에서는 미사용임을 명시한다
- 저장소는 단일 모노레포 `bistel-final`을 사용한다. 애플리케이션 코드는 `backend/·frontend/`, 공통 산출물은 `docs/`, 통합 Compose와 공통 설정은 저장소 루트에서 관리한다
- 배포 패키지의 데이터·스키마·기준정보는 수정하지 않는다
- 산출물 마감: 요구사항 정의서 8/7 · 시스템 설계서 8/14 · 소스코드 9/4 · 테스트·평가 결과서 9/8 · 최종 발표 9/11

13. 테스트 요구사항

CI 자동화 여부와 관계없이 다음 테스트는 유지하며, 담당자가 로컬에서 실행하고 PR 확인 내용에 결과를 남긴다.

테스트	담당	관련 요구사항
FDC 요약 1,600건 재계산 일치 테스트	A	FR-A-01
R01·R02·R03 전체 51건·발생 위치 재현 테스트	A	FR-A-02, 8.1
R03 LOT 경계·RECIPE STEP 카·임계점 1회 발행·재무장 테스트	A	FR-A-02, 8.1
IsolationForest LOT 단위 분리·평가 재현성·ML 실행 전후 fdc_alarm 51건 불변 테스트	A	FR-A-03
알람 대시보드 기간 자동 적용·알람/OOS/OOC·일별 추이·파라미터 TOP5·설비별 건수·최근 5건·C 승인 대기 목록 연동 테스트	A+C	FR-A-06, FR-A-07
Trace 카탈로그·센서/WAFER 다중 검색·기간 경계·한계선 5종·ET_REFL <code>upper_only=true</code> 테스트	A	FR-A-06, FR-A-07
Neo4j 노드·관계 건수 및 관계 골드셋 6건 정확도 테스트	B	FR-B-01, FR-B-07
문서 검색 Recall@4·MRR 평가	B	FR-B-07
decide_action 결정표 단위 테스트	C	FR-C-03, NFR-04
반복 LOT·하류 전파·정상 복귀 및 조건 충돌 우선순위 테스트(세 조건 모두 양성·음성 fixture 사용, 하류 전파 양성은 합성 fixture)	C	FR-C-03, 8.2
런타임 incident당 agent_run 1건·대표 alarm_id·포함 alarm_ids 추적 테스트	C	FR-C-01, FR-C-09, FR-C-14
동일 분류 로직의 오프라인 알람 51건 정량평가(Accuracy·Macro-F1 비강제 목표 0.80) 및 TMD 합성 fixture 테스트	C	FR-C-15
동일 고정 시나리오의 Agent Level 1·2 완료율·Tool 호출 수·지연시간·토큰 비교	C	FR-C-02
Agent Tool 예산·전송 예약·HITL 누적·checkpoint 유실 시 연속 호출 이력 복원·잔여 예산 내 재시도 테스트	C	FR-C-08, NFR-03
ALM-0031 복합 이상 E2E(PHOTO incident 선행 처리·중복 조치 미생성)	C	FR-C-10
전체 51건 배치 순서를 바꿔도 ALM-0031 상류 PHOTO LOT_HOLD 근거가 유지되는지 검증	C	FR-C-10, FR-C-14

테스트	담당	관련 요구사항
승인 중복·EXPIRED 처리 409·무변경·승인자 필드 동기화·반려 승인자 NULL 테스트	C	FR-C-05, 8.3
send_action 정상 중복·응답 유실·timeout·FAILED 수동 재실행 먹등성 테스트	C	FR-C-06, FR-C-09, FR-C-12
Tool별 고정 정상 1건 이상·오입력 또는 timeout 1건 이상 계약 테스트(ok·필수 필드·reason, 예외 미발생) — 고정 케이스 계약 준수율 100%	전원(각자 Tool)	NFR-09
Text2SQL 쓰기·다중 문장·테이블·컬럼 화이트리스트·위험 함수·시스템 카탈로그 방어 6종 및 재귀 AST 테스트	D	FR-D-02-03, 9.2
Text2SQL 정책 거부 HTTP 200·is_rejected=true·미실행·로그 기록과 malformed 요청 422 분리 테스트	D	FR-D-02, FR-D-05, NFR-10
Text2SQL 교정 가능 오류 1회 재생성·재실패 안전 종료·정책 위반 재생성 0회 테스트	D	FR-D-02, 9.2
Text2SQL 골드 12건 실행 정확도 평가(실수 허용오차·정렬·시각화 계획 포함)	D	FR-D-08, 9.1
운영 /analytics/query 최신 action_history와 전용 화면 정합·평가 DB base table 격리·운영 DSN fallback 금지 테스트	D	FR-D-03, FR-D-05, FR-D-08
React 8화면 공통 라우팅·알람 상세 상태 복원·화면 간 Agent 실행/조치/알람 링크 이동 테스트	공동	FR-I-02, FR-I-03
골드 시나리오 E2E 테스트	4인 공동	부록 B
incident 집계·agent_run 10건·조치 10건·동시성·자동 배치 즉시 재실행 0건 테스트	C	FR-C-09, FR-C-14
PostgreSQL Checkpoint 별도 초기화·테이블 검증·재실행 안전성 및 HITL 재개 테스트	C	FR-C-04, 12장
공용 서버 kosa_readonly 기본 자격증명 전환 후 기존 로그인 실패·허용 SELECT 성공·쓰기/비허용 접근 거부 테스트	공동(C·D 검토)	NFR-01, NFR-02, NFR-14

테스트 데이터 격리 원칙

- Text2SQL 평가 DB의 16개 평가 대상 base table은 배포 초기 상태를 유지하며 action_history 10건(승인 대기 2건 포함)을 적재한다. 9장의 기대 결과는 이 base table 상태를 기준으로 채점한다. 평가 이력용 nl_query_log 누적은 허용하되 기존 데이터·content hash에서 제외한다
- 위 분리는 골드 평가 격리 원칙이다. 일반 운영 /analytics/query와 nl_query_log는 Agent·승인·감사 기능이 사용하는 운영 DB의 최신 허용 테이블을 읽고 기록하며, 평가 one-shot만 별도 Text2SQL 평가 DB 연결을 사용한다. approval_request·audit_log는 Text2SQL allowlist 밖이므로 해당 질문은 정책 거부하고 전용 승인·감사 화면/API로 안내한다
- Agent E2E DB는 fd_c_alarm 51건 등 입력 데이터는 유지하되, 실행 시작 시 action_history·agent_run·agent_run_alarm·agent_tool_call·approval_request·audit_log·action_delivery·운영 nl_query_log와 Checkpoint 실행 데이터를 빈 상태로 둔다(checkpoint_migrations는 보존). 운영 nl_query_log는 운영 DB에 함께 있으므로 초기화 대상이며, 평가 DB의 nl_query_log는 초기화하지 않는다
- ACT-0001~0010은 Agent E2E 대상 action_history에 적재하지 않고 CSV·JSON 또는 별도 expected fixture로 보관하여 신규 생성 조치 10건과 비교한다
- Agent E2E는 별도 테스트 DB·스키마 또는 매 실행 전 초기화가 보장되는 격리 환경에서 수행한다. 공용 DB의 초기 정답 데이터를 삭제하거나 덮어쓰지 않는다
- Text2SQL 평가 DB와 Agent E2E DB는 목적과 초기 상태가 다르므로 동일 DB 상태를 공유하지 않는다

부록 A. 요구사항 추적 매트릭스

요구사항	담당	골든 시나리오	설계서 절	테스트 케이스
FR-A-01~09 (08 결번)	신동원	1, 2	5, 10.2, 12, 15	(9/8 기재)
FR-B-01~08	강연권	1, 2	6, 10.3, 12, 15	(9/8 기재)
FR-C-01~15	방대혁	1, 2, 3, 4	3~4, 7~8, 10.4, 11~12, 14~15	(9/8 기재)
FR-D-01~10	천승현	4(감사로그 검증 관점, FR-D-07) — 그 외 독립 기능	9, 10.5, 11~12, 14~15	(9/8 기재)
FR-I-01~07	공동 (통합 관리 방대혁)	1, 2, 3, 4	1~2, 10.1, 12~15	(9/8 기재)
NFR-01~18	전원	2, 4	2.3, 3~4, 7~10, 13~15	(9/8 기재)

골든 시나리오: ①자동조치 전송 ②EQP_HOLD 승인 후 전송(4주차 분기점) ③반려 후 미전송 ④Tool-n8n 실패 처리 — 상세는 부록 B.

부록 B. 골든 시나리오 상세

골든 시나리오 5종

완료 판정 기준 — 정상 3 종 · 장애 2 종

공통 전제 <code>fdc_alarm</code> 51건 등 입력 데이터는 유지하고, 실행-조치-승인-감사-전송 테이블만 비운 격리 DB 에서 실행한다. 공용 서버가 아닌 별도 DB 를 사용하며, 컨테이너 중지 검증은 테스트 Compose 스택에서만 수행한다.	
1 자동조치 성공 입력 ALM-0001 LOT-260003 · R02_OOC	- action_code = MONITOR · send_channel = EMAIL - approval_status = AUTO · approved_by = 'system' - approved_at = created_at - send_status = SENT - agent_run = COMPLETED · ended_at 기록 AGENT_RUN_COMPLETED 감사로그
2 EQP_HOLD 승인 입력 ALM-0022 LOT-260007 · PHO-01-C1 · R03	- 결정 시 action PENDING/WAITING + approval PENDING 동시 생성 - 승인 시 기존 행을 APPROVED/WAITING 으로 갱신 - approved_by = decided_by - agent_run WAITING_APPROVAL → RUNNING → COMPLETED - 새 조치 행을 만들지 않는다 AGENT_RUN_COMPLETED 감사로그
3 EQP_HOLD 반려 입력 ALM-0048 LOT-260010 · ETC-01-C1 · R03	- 결정 시 action PENDING/WAITING + approval PENDING 동시 생성 - 반려 시 기존 행을 REJECTED/CANCELED 로 갱신 - approved_by = approved_at 은 NULL 유지 - agent_run WAITING_APPROVAL → RUNNING → COMPLETED - 전송하지 않는다 APPROVAL_DECIDED · AGENT_RUN_COMPLETED 감사로그
4-A Tool 장애 — 조치 전송 이전 입력 격리 환경 잘못된 Meo4j URI · Tool mock	- Tool 은 예외를 던지지 않고 (ok:false, reason) 반환 - agent_tool_call = ERROR 또는 TIMEOUT · error_msg 기록 - 재시도 실패 후 agent_run = FAILED - action_history 행을 만들지 않는다 - API 프로세스 생존 AGENT_RUN_FAILED 감사로그
4-B n8n 전송 장애 — 승인 이후 입력 격리 webhook HTTP 500 또는 timeout	- 승인 트랜잭션은 이미 커밋되어 롤백되지 않는다 - approval_request = APPROVED 유지 - agent_tool_call = ERROR 또는 TIMEOUT - action_history.send_status = FAILED - 같은 action_id 로 재시도 가능 ACTION_SEND_FAILED 감사로그
다섯 개가 모두 통과해야 Agent · HITL 핵심 경로를 완료로 판정한다. 정상 3 종은 실제 API 와 배포 기준 데이터를 쓰며 UI · Backend Mock 을 쓰지 않는다. 장애 2 종만 통제된 실패 주입을 위해 별도 구성을 쓴다.	

그림 10. 골든 시나리오 5종 — 정상 3종·장애 2종

공통 실행 전제: 골든 시나리오는 `fdc_alarm` 51건 등 입력 데이터는 유지하되

`action_history`·`agent_run`·`agent_run_alarm`·`agent_tool_call`·`approval_request`·`audit_log`·`action_delivery`·운영 `n1_query_log`와 Checkpoint 실행 데이터가 빈 Agent E2E DB에서 실행한다. ACT-0001~0010은 대상 테이블에 적재하지 않고 별도 expected fixture로만 사용한다.

FR-C-10 ALM-0031 복합 이상 E2E 추가 전제: 같은 빈 Agent E2E DB에서 LOT-260008 PHOTO incident를 먼저 처리해 LOT_HOLD 조치를 신규 생성한 뒤 ALM-0031을 실행한다. 이 선행 조치는 expected fixture ACT-0007과 조치 코드·incident가 대응하지만 실제 action_id는 새로 생성하며, ACT-0007 원본 행을 DB에 미리 적재하지 않는다.

위 선행 처리 순서는 ALM-0031 단독 시나리오의 재현 절차일 뿐 전체 자동 배치의 실행 순서를 고정하지 않는다. 전체 51건 배치는 incident 순서를 바꾸어도 모든 incident의 판단 결과를 이용할 수 있어야 하며, ALM-0031 분석 결과에는 항상 같은 LOT의 상류 PHOTO LOT_HOLD 판단 근거가 포함되어야 한다. 구현은 시스템설계서 v1.2 4.3에서 확정한 1단계 전체 incident 계획 계산 → 2단계 Agent 실행·근거 결합 방식을 사용하며, 이는 본 요구사항의 실행 순서 독립성을 구현하는 내부 설계다.

시나리오 1. 자동조치 성공

- 입력 alarm_id: ALM-0001 (LOT-260003 / R02_OOC)
- 예상 action_code: MONITOR
- 예상 send_channel: EMAIL
- 검증: action_history.approval_status=AUTO, approved_by='system', approved_at=created_at, 최종 send_status=SENT
- agent_run.status = COMPLETED, ended_at 기록, AGENT_RUN_COMPLETED 감사로그 기록

시나리오 2. EQP_HOLD 승인

- 입력 R03 alarm_id: ALM-0022 (LOT-260007 / PHO-01-C1)
- 검증: 조치 결정 시 action_history **PENDING/WAITING**과 approval_request **PENDING**이 함께 생성되고, 승인 시 기존 action_history가 **APPROVED/WAITING**으로 갱신되며 approved_by=decided_by, approved_at=decided_at이 일치한 뒤 send_status **SENDING → SENT**, n8n 모의 전송 정확히 1회
- agent_run.status = WAITING_APPROVAL → RUNNING → COMPLETED 전이 확인, AGENT_RUN_COMPLETED 감사로그 기록

시나리오 3. EQP_HOLD 반려

- 입력 R03 alarm_id: ALM-0048 (LOT-260010 / ETC-01-C1)
- 검증: 조치 결정 시 action_history **PENDING/WAITING**과 approval_request **PENDING**이 함께 생성되고, 반려 시 새 조치 행을 만들지 않고 기존 행을 **REJECTED/CANCELED**로 갱신하며 approved_by/approved_at은 NULL 유지, n8n 미호출
- agent_run.status = WAITING_APPROVAL → RUNNING → COMPLETED 전이 확인, ended_at 기록, APPROVAL_DECIDED·AGENT_RUN_COMPLETED 감사로그 기록

시나리오 4-A. Tool 장애 (조치 전송 이전)

- 실패 주입 방법: 격리 테스트 환경에서 잘못된 Neo4j URI, dependency override 또는 Tool mock으로 {ok:false, reason} 반환. 공용 서버 컨테이너는 중지하지 않는다
- 검증:
 - Tool은 예외를 던지지 않고 {ok:false, reason} 반환 (NFR-09) - agent_tool_call.status = ERROR 또는 TIMEOUT, error_msg 기록 - 재시도 상한(8.5) 소진 후 agent_run.status = FAILED, AGENT_RUN_FAILED 감사로그 기록 - 조치 전송 이전이므로 action_history 행과 ACTION_SEND_FAILED는 기록하지 않는다 - API 프로세스 생존 (NFR-16)

시나리오 4-B. n8n 전송 장애 (승인 이후)

- 실패 주입 방법: 격리 테스트 webhook이 HTTP 500 또는 timeout을 반환하도록 구성. 공용 서버 컨테이너는 중지하지 않으며, 컨테이너 중지 검증은 별도 테스트 Compose 스택에서만 수행
- 검증:
 - 승인 트랜잭션은 이미 커밋되어 롤백되지 않는다(8.3). approval_request.status = APPROVED 유지 - agent_tool_call.status = ERROR 또는 TIMEOUT (n8n 전송은 send_action Tool 내부에서 수행되므로 전송 실패 = 해당 Tool 호출 실패) - action_history.send_status = FAILED - ACTION_SEND_FAILED 감사로그 기록 - 재시도 상한 소진 후 agent_run.status = FAILED - 내부 재시도와 FAILED 수동 재실행 모두 기존 action_history의 동일 action_id를 사용하며 신규 조치 행을 생성하지 않음 - 동일 action_id 재시도 시 중복 전송 미발생. 특히 n8n이 모의 발송을 처리한 뒤 응답만 timeout되는 fixture에서 재시도해도 downstream 효과는 총 1회 (FR-C-06-09-12) - FR-D-07 감사로그 화면에서 실패 이벤트 조회 확인 (D 검증 관점)

순수 연쇄 이상 규칙은 유일한 해당 케이스(LOT-260008 w1)에 트리거 알람이 없어 E2E 검증이 불가능하므로, 골든 시나리오에 포함하지 않고 decide_action 단위 테스트(FR-C-03-FR-C-10)로만 검증한다.

부록 C. 확정 사항 및 시스템 설계서 이월 항목

C.1 요구사항 확정 사항

항목	확정값
팀명	포토에치
저장소	단일 모노레포 <code>bistel-final: backend/ / frontend/ / docs/ / 루트 docker-compose.yml</code>
R03_CONSEC	<code>(chamber_id, sensor_id, recipe_step_no) / chamber_wafer_cum ASC</code> / LOT 경계 통과 / 최초 3 도달 시 1회 발행 / 비OOS에서 재무장
반복 LOT	동일 챔버·센서·RECIPE STEP·규칙이 2개 연속 처리 LOT에서 반복되면 한 단계 상향, 최대 LOT_HOLD
하류 전파	동일 LOT·WAFER의 NEXT_STEP 하류 <code>track_in_at <= alarm.occurred_at</code> 일 때 한 단계 상향, 최대 LOT_HOLD. 배포 양성 사례가 없어 합성 fixture 단위 테스트로 검증
정상 복귀	챔버상 바로 다음 실제 처리 WAFER의 동일 판별 키가 IN_CONTROL이고 상향 조건이 없으면 NOTIFY→MONITOR. 동일 키 요약이 없으면 이후 관측까지 건너뛰지 않음
조치 단위	<code>(lot_id, chamber_id)</code> incident 전체 집계 후 최고 조치 1건 생성·전송. 순차 재상향은 초기 범위 밖
조치 이력 생성	조치 확정 시 incident당 action_history 1건 생성. 자동 조치는 AUTO/WAITING-system 승인자, EQP_HOLD는 approval_request와 함께 PENDING/WAITING-승인자 NULL로 생성. 승인 시 decided_by/decided_at을 기존 action_history에 동기화하고 반려 시 승인자 NULL을 유지하며 기존 행만 갱신. 역할분담 v9.6과 동일하며 v9.3의 승인 결정 시 생성 문구를 대체
CD_AEI 상향	동일 LOT·WAFER 직접 연결 FAIL만 한 단계 상향, 최대 LOT_HOLD
Agent 재시도·예산	AGENT_MAX_RETRY=3은 최초 호출 이후 최대 3회 재시도이며 AGENT_MAX_TOOL_CALLS=8에 포함. 조치 가능 경로는 최초 send_action 1회를 예약하고 HITL 재개 후에도 누적 호출 수를 유지
배치 실행 단위·중복 방지	<code>(lot_id, chamber_id)</code> incident당 agent_run 1건·대표 alarm_id 1건. 포함된 모든 alarm_id를 같은 실행의 처리 대상으로 확정하며 동일 데이터 즉시 재실행 시 신규 Agent 실행·조치·전송 0건
배치 연쇄 근거	전체 51건 자동 배치의 incident 순서와 관계없이 ALM-0031 결과에 상류 PHOTO LOT_HOLD 판단 근거 포함
수동 재실행	기존 FAILED 조치가 있으면 동일 action_id 재사용. 전송 전 실패로 action_history가 없을 때만 신규 조치 생성
IsolationForest	LOT 단위 분리·고정 random_state 평가 필수, P-R-F1 각 0.80은 비강제 성능 목표
ML 알람	초기 필수 범위에서 IsolationForest는 anomaly_score·정상/이상 예측만 제공하고 fdc_alarm 추가 생성 금지. 규칙 알람 51건 불변
RAG·관계	Recall@4 ≥ 0.80, MRR ≥ 0.70 / 관계 골드셋 6건 정확도 100%(챔버 4건+장비 2건, 상·하류 경계 포함)
Fault Code 분류	런타임의 incident당 agent_run 1건과 별도로 동일 분류 로직을 fdc_alarm 51개 행에 오프라인 전수 평가(FOC 22 / RFM 15 / MFD 14), Accuracy·클래스별 P-R-F1·Macro-F1·혼동행렬 산출, Accuracy·Macro-F1 각 0.80 비강제 목표, TMD 합성 fixture 검증. 평가를 위해 agent_run 51건을 생성하지 않음

항목	확정값
Text2SQL	운영 질의는 Agent 운영 DB의 최신 허용 테이블을 조회하고 골드 평가는 배포 초기 상태의 별도 DB에서 실행 / 골드 12건 중 10건 이상(실수 절대오차 0.001, 정렬 요구 문항만 순서 비교, 시각화 문항은 결과+chart_type-x-y 비교) / 쓰기·다중 문장·비허용 테이블·존재하지 않는 컬럼·위험 함수·시스템 카탈로그 방어 6/6 안전 처리 / 교정 가능한 생성 오류만 1회 재생성 / REST 정책 거부는 HTTP 200- is_rejected=true -SQL 미실행, malformed 요청만 422
알람 대시보드·Trace	기간 미지정 시 선택 계층의 최소·최대 알람일 자동 적용 및 최신 reference_date 반환 / 기간·AREA·설비·챔버 필터 / 알람·OOS/OOC·일별 추이·파라미터 TOP5·설비/챔버별 건수·승인 대기 목록·최근 알람 5건 / 계측 PASS율·챔버 상태 카드 제외 / Trace 카탈로그+다중 검색, 한계선 5종과 ET_REFL upper_only=true (원본 스키마 무수정)
Tool 호출 로그	Agent 흐름의 A-B-C Tool은 agent_tool_call, 독립 Analytics의 D Tool은 nl_query_log에 기록. D Tool을 Agent에 연결한 경우에만 agent_tool_call에도 기록
Tool 수·범위	멘토 원안 Agent Tool 4종은 유지하며 D의 독립 Analytics Tool 1종을 공통 계약에 추가해 총 5종으로 관리. 초기 D Tool은 LangGraph-Agent 호출 예산 밖
공용 readonly 자격증명	기존 교육장 서버도 배포 기본 비밀번호를 사용하지 않으며 원본 스키마 무수정·팀/멘토 공유 후 1회 전환. 이전 로그인 실패·새 SELECT 성공·쓰기/비허용 접근 거부를 검증
PostgreSQL Checkpoint	01_schema.sql은 수정하지 않으며 PostgresSaver.setup()의 필수 테이블 생성·내부 마이그레이션은 팀 공유·멘토 확인 후 쓰기 계정으로 수행하는 별도 1회 초기화 작업으로 관리
Agent 실행 지연시간	agent_run.llm_model·latency_ms는 성공·실패 모두 필수. latency_ms는 실제 처리시간이며 HITL 사람 대기시간 제외, 토큰은 제공자 반환 시 기록
승인 만료	자동 만료 스케줄러는 범위 밖. EXPIRED는 기존·테스트 fixture의 터미널 상태로만 처리하며 승인 API는 409·관련 데이터 무변경
골드 시나리오	ALM-0001 자동 / ALM-0022 승인 / ALM-0048 반려 / 격리 장애 주입
n8n	n8nio/n8n:2.32.7 / 검증 digest sha256:882b126a8ddd0646e7d17ec47630e7704615e4647f3363471859fddc3f8946e2
전송 역등성	동일 action_id의 정상 중복·응답 유실·timeout 재시도에서도 downstream 효과 최대 1회

C.2 시스템 설계서로 이월하는 구현 상세

- incident 중복 방지를 부분 고유 인덱스·advisory lock·트랜잭션 중 어떤 방식으로 구현할지와 동시 실행 잠금 순서
- 부분 고유 인덱스 채택 시 **send_status IS DISTINCT FROM 'CANCELED'** 조건 및 별도 마이그레이션 SQL
- incident 처리 시작 시 포함된 모든 alarm_id를 다음 자동 배치의 선택 대상에서 제외하는 완료·포함 관계 저장 방식. 런타임은 incident당 agent_run 1건으로 고정하므로 **agent_run.alarm_id**에 저장할 대표 alarm_id의 결정론적 선택 규칙과 전체 alarm_ids를 State-evidence_json·별도 연결 테이블 중 어디에 보존할지 함께 확정
- 전체 51건 배치에서 incident 처리 순서와 무관하게 연쇄 근거를 결합하는 방식. 시스템설계서 v1.2 4.3은 1단계 전체 incident 계획 계산 후 2단계 Agent 실행·관계 근거 결합 방식으로 구체화하며 ALM-0031 순서 섞기 테스트로 검증
- approval_request**에 action_id·chamber_id가 없으므로 승인 API가 대상 action_history를 유일하게 찾는 연결 방식. **approval_request.agent_run_id → agent_run(lot_id·chamber_id) → 해당 incident의 유효 action_history** 조회 규칙 또는 LangGraph State의 action_id 보존 방식을 확정하고 동시 승인 시 모호성이 없음을 보장
- incident 내 다수 알람 중 **action_history.trigger_alarm_lot_hist_id**에 기록할 대표 lot_hist_id의 결정론적 선택 규칙. 단순 R03 알람 행과 배포 expected fixture의 trigger 값이 항상 같지 않으므로 조치 우선순위·시간·ID 등을 이용한 타이브레이크와 fixture 비교 범위를 명시
- fdc_summary**의 WAFER당 복수 센서·RECIPE STEP 행을 **get_fdc_summary**의 WAFER당 단일 anomaly_score로 만드는 feature pivot·집계 규칙과 누락 센서 처리, 정확히 1개 점수를 반환하는 계약

- 운영 데이터에서 `chamber_wafer_cum`이 중복될 때의 R03 보조 정렬 키와 연속 상태 저장 방식
- n8n의 `action_id` 역등 키 저장·조회 방식과 `timeout` 응답 유실 처리. 프로세스 종료 등으로 SENDING 상태가 고착됐다고 판정하는 시간과 n8n 처리 결과 조회·동일 `action_id` 복구 절차
- Neo4j-n8n 장애 주입용 `dependency override·mock webhook·별도 Compose` 구성
- IsolationForest 최종 feature 목록, 정상 전용 또는 전체 표본 학습 방식, 평가 실행 절차
- PostgreSQL Checkpoint 초기화 절차: `PostgresSaver.setup()`이 생성·변경하는 테이블 목록, 실행 계정, 공용 DB 최초 1회 실행 시점, 애플리케이션 시작 시 자동 DDL 금지, 재실행 안전성 검증과 실패 시 복구 절차. 배포 `01_schema.sql`은 수정하지 않고 별도 마이그레이션·운영 절차로 관리
- Text2SQL 테이블 검증 시 `sqlglot Table` 노드의 `catalog + db + name`을 정규화하여 전체 식별자로 검사하는 방식. 시스템 테이블 거부 목록에 의존하지 않고 애플리케이션 허용 테이블만 통과시키는 `allowlist`를 적용하며, `pg_class`처럼 스키마가 생략된 시스템 테이블도 허용 목록에 없으면 거부. CTE·서브쿼리를 포함한 AST 전체를 재귀 순회하여 쓰기·DDL·SELECT INTO·잠금 노드를 차단하는 구체적 노드 목록과 검증 순서를 명시
- 모노레포 루트 `docker-compose.yml`에서 사용할 PostgreSQL/pgvector·Neo4j·n8n·Backend·Frontend 전체 이미지 태그와 digest, `backend/·frontend/` build context, Frontend Node 고정 버전, 패키지 설치·빌드 절차. n8n만이 아니라 통합 Compose의 모든 서비스가 재현 가능해야 함
- Agent Level 1·2 비교에 사용할 고정 시나리오 집합, 반복 횟수, 완료율·평균 Tool 호출 수·지연시간·토큰 사용량 집계 방법
- `agent_run.latency_ms` 측정 경계: 시작·종료 시점, 여러 LLM·Tool 호출의 합산 방식, 오류 실행 기록 방식과 HITL 사람 대기시간 제외 방법. Level 1·2 비교는 자동조치 또는 승인 응답을 고정한 fixture로 사람 반응시간의 영향을 제거
- nullable incident key backfill·원본 식별자 정합 검사·NOT NULL 전환 후 부분 고유 인덱스를 생성하는 migration 순서와 검증
- 운영 Text2SQL과 평가 one-shot의 DSN·로그 pool·Compose 환경 주입 분리, 평가 source hash·기준 건수 사전검증과 runtime fallback 금지
- `agent_tool_call` 연속 시도 예약을 기준으로 8회 예산을 복원하고 최초 `send_action`을 예약하는 방식, checkpoint 유실 복구의 잔여 예산 처리
- 공용 교육장 서버의 원본 스키마를 수정하지 않는 최소권한 role 4종·기본 자격증명 전환, 기존 pool 종료와 허용/금지 권한 재검증
- API DTO, LangGraph State·Node·Edge, Repository 구조와 트랜잭션 경계의 구체적 구현

위 항목은 본 문서에서 확정한 사용자 관점 동작과 수용 기준을 변경하지 않는 범위에서 시스템 설계서에 구체화한다. 설계 과정에서 기능 범위나 결과가 달라질 경우 요구사항 정의서를 먼저 개정한다.